



Universidad Nacional
Autónoma de México

Facultad de Ciencias



Almacenes y Minería de Datos

PROYECTO FINAL

Riesgo Climático y Seguridad Alimentaria

Profesora: Jessica Santizo Galicia

Ayudante: Diego Antonio Villalba González

Ayudante: Ares Gael Castro Romero

Integrantes:

González Téllez Lorena - 321288952

López Rodríguez Leslie Renée - 321171915

Marentes Mosqueda Bruno Sebastián - 321260606

Raya García Marco Antonio - 422073121

Semestre 2026-2

Fecha de entrega: 10 de junio del 2026

ÍNDICE

INTRODUCCIÓN.....	5
Descripción del Problema.....	5
Relevancia de la Problemática abordada.....	6
Objetivos de Análisis.....	6
Elección del Conjunto de Datos (dataset).....	7
CONCEPTOS Y CONTEXTO.....	8
DESCRIPCIÓN DEL DATASET.....	10
Fuente.....	10
Descripción de las Variables.....	10
LIMPIEZA Y PREPARACIÓN DE DATOS.....	13
Valores Faltantes.....	13
Registros Duplicados.....	14
Valores Atípicos.....	14
Transformaciones Aplicadas.....	17
ANÁLISIS EXPLORATORIO.....	19
Estadísticas Descriptivas de Variables Numéricas y Categóricas.....	19
Distribuciones de Variables Numéricas.....	21
Matriz de Correlaciones.....	23
Relación entre Área Sembrada y Área Siniestrada.....	25
Tendencias en Variables Categóricas.....	26
Cultivos más frecuentes en los Estados más frecuentes.....	28
Cultivos a lo largo del tiempo.....	29
Área Siniestrada por Estado.....	31
CLUSTERING, K-MEANS.....	33
Objetivo del agrupamiento.....	33
Fundamentos Teóricos del Agrupamiento.....	33
Aprendizaje No Supervisado y Particionamiento.....	33
Representación Vectorial y Métrica de Proximidad.....	34
Centroide y Función Objetivo.....	34
Heurística del Algoritmo de LLoyd.....	35
Preparación de los datos para el agrupamiento.....	36
Agregación a nivel municipal.....	36
Variables seleccionadas.....	36
Transformaciones y escalado.....	37
Selección del Número Óptimo de Clústeres.....	38
Método del codo.....	38
Coeficiente de silueta.....	38
Entrenamiento del Modelo y Visualización con PCA.....	39
Caracterización e Interpretación de los Perfiles.....	40
Clúster 0: Agricultura de Temporal de Gran Escala (939 municipios).....	42
Clúster 1: Agricultura Tradicional de Temporal y Subsistencia a Pequeña Escala (954 municipios).....	42

Clúster 2: Corredores Agrícolas Comerciales de Riego y Alta Productividad (486 municipios).....	43
Clúster 3: Zonas de Siniestralidad Crónica y Vulnerabilidad Climática Crítica (79 municipios).....	43
Validación geográfica de los perfiles.....	43
Comparación de siniestralidad entre perfiles.....	45
Complementariedad con el Modelo Supervisado.....	47
Persistencia y Reutilización del Modelo.....	48
Patrón de Diseño: Pipeline.....	48
MODELO SUPERVISADO 2: CLASIFICACIÓN DE NIVEL DE RIESGO CON XGBOOST	50
Objetivo del modelo.....	50
¿Por qué XGBoost?.....	51
PREPARACIÓN DE LOS DATOS PARA EL MODELO.....	52
Ingeniería de variables.....	52
Prevención de fuga de información (data leakage).....	52
Partición temporal (no aleatoria).....	53
Tratamiento del desbalance de clases.....	53
MODELO BASE (BASELINE).....	54
Comparación con la línea base trivial (clasificador mayoritario).....	55
REGULARIZACIÓN: gamma, lambda Y alpha.....	56
Experimento 1 — Efecto individual de gamma.....	56
Experimento 2 — Efecto individual de lambda (L2).....	57
Experimento 3 — Efecto individual de alpha (L1).....	57
Experimento 4 — Búsqueda conjunta con RandomizedSearchCV.....	58
Tabla comparativa de las estrategias de regularización.....	59
MODELO FINAL Y EVALUACIÓN.....	60
Comparación entre el baseline y el modelo optimizado.....	62
INTERPRETABILIDAD DEL MODELO.....	64
Importancia de variables (nativa de XGBoost).....	64
Valores SHAP (SHapley Additive exPlanations).....	65
ANÁLISIS DE ERRORES.....	67
VALIDACIÓN CRUZADA Y ROBUSTEZ.....	68
CIERRE DE LA PARTE 1 Y MOTIVACIÓN DE LAS SIGUIENTES.....	70
ENRIQUECIMIENTO CON VARIABLES CLIMÁTICAS.....	71
Motivación.....	71
Fuentes de datos climáticos.....	71
Reentrenamiento controlado (ablación).....	72
MEJORAS METODOLÓGICAS ADICIONALES.....	76
Criterio de optimización:.....	76
Target Encoding (codificación por tasa de siniestro).....	76
Arquitectura en dos etapas.....	77
Búsqueda bayesiana de hiperparámetros (Optuna).....	78
Calibración de probabilidades.....	79
Ajuste del umbral de decisión.....	80

Resumen de las mejoras.....	81
EVOLUCIÓN DEL MODELO: LAS TRES VERSIONES.....	82
PERSISTENCIA Y REUTILIZACIÓN DEL MODELO.....	83
CONCLUSIONES.....	84
MODELO SUPERVISADO 1: CLASIFICACIÓN DE NIVEL DE RIESGO CON CATBOOST..	
85	
Objetivo del modelo.....	85
¿Por qué CatBoost?.....	85
Preparación de los datos.....	86
Variables seleccionadas.....	86
Corrección del leakage en proporcion_siniestro.....	86
Partición temporal.....	86
Distribución de la variable objetivo y análisis exploratorio.....	87
Línea Base.....	89
Optimización de hiperparámetros.....	91
Evaluación final en el conjunto de prueba.....	92
Interpretabilidad con SHAP.....	95
Persistencia del modelo.....	97
Conclusiones del modelo.....	98
ARQUITECTURA Y DISEÑO.....	99
Patrón de diseño implementado.....	99
Pipeline.....	99
Strategy.....	99
Layered Architecture.....	100
REUTILIZACIÓN DEL MODELO.....	104
Clustering, K-Means.....	104
Modelo Supervisado 1, CatBoost.....	104
Modelo Supervisado 2, XGBoost.....	107
Conclusión.....	108
CONTEXTO Y OBJETIVOS DEL PROYECTO.....	108
CONCLUSIONES DEL ANÁLISIS NO SUPERVISADO (CLUSTERING).....	109
CONCLUSIONES DEL PRIMER MODELO SUPERVISADO (CATBOOST).....	110
CONCLUSIONES DEL SEGUNDO MODELO SUPERVISADO (XGBOOST + CLIMA).....	112
SÍNTESIS: LO QUE LOS TRES MÓDULOS DICEN EN CONJUNTO.....	113
LIMITACIONES.....	115
TRABAJO FUTURO Y RECOMENDACIONES.....	116
CIERRE.....	116
REFERENCIAS.....	117

INTRODUCCIÓN

Descripción del Problema

La relación entre la agroindustria y la economía en México es de suma relevancia, debido a que ambos sectores se complementan para brindar un mayor bienestar a la población. Nuestro país cuenta con una extensa variedad de frutas y verduras que se cultivan diariamente en nuestras tierras; sin embargo, más allá de la siembra, el proceso comercial de los cultivos mexicanos es un auténtico motor económico. De este modo, la agricultura se posiciona como uno de los pilares fundamentales de la economía mexicana y un componente crítico para la seguridad alimentaria del país.

A pesar de su riqueza y potencial, la agricultura mexicana enfrenta numerosos retos que amenazan su viabilidad y sostenibilidad. Dentro de estos retos destaca el cambio climático: las sequías severas y las inundaciones inesperadas se están volviendo cada vez más comunes, lo que plantea serias preocupaciones sobre la capacidad del país para alimentar a su población en el futuro. Por otro lado, la infraestructura hídrica en México sigue siendo deficiente y desigual, incrementando drásticamente el riesgo de perder las siembras en el campo. La falta de apoyo y la ausencia de programas que fomenten la mitigación de estos riesgos han obstaculizado el desarrollo sostenible del sector.

Estos retos son complejos y multifacéticos, por lo que requieren la participación de diversos sectores públicos y privados. Para garantizar la seguridad alimentaria es crucial que se implementen estrategias integrales que aborden el problema de manera holística.

El problema central radica en que, históricamente, la evaluación de siniestros agrícolas (pérdida de cultivos en el campo) se realiza de manera reactiva; es decir, después de que ocurre la pérdida. Existe una carencia de herramientas analíticas predictivas que permitan a los tomadores de decisiones, productores y dependencias gubernamentales anticipar el riesgo antes de que comience el ciclo de siembra. Sin una comprensión profunda de qué combinaciones de factores (ubicación geográfica, tipo de cultivo, modalidad hídrica y ciclo productivo) maximizan la probabilidad de siniestro, resulta imposible implementar políticas preventivas eficientes o recomendar cambios de cultivo a los productores.

Es por ello que este proyecto busca analizar el fenómeno del área siniestrada durante los ciclos de siembra en México. El objetivo es mitigar la actual falta de anticipación proporcionando modelos que permitan prever los riesgos antes de que concluya el ciclo agrícola, transformando un enfoque tradicionalmente reactivo en uno proactivo e informado.

Relevancia de la Problemática abordada

Este problema tiene una relevancia multidimensional crítica para el país:

1. **Impacto Económico:** La agricultura es el sustento de millones de familias mexicanas. Cuando el área siniestrada aumenta, los productores (especialmente los pequeños agricultores) sufren pérdidas de capital irrecuperables, lo que incrementa la pobreza rural y obliga a la migración. Además, la disminución en el volumen de producción nacional encarece los productos básicos, elevando la inflación.
2. **Impacto Ambiental y Climático:** El cambio climático ha intensificado la frecuencia y severidad de sequías y heladas en México. Debido a la dependencia climática, el riesgo de siniestro es un problema que crecerá en magnitud durante los próximos años si no se toman decisiones basadas en datos.
3. **Seguridad Alimentaria:** La pérdida recurrente de hectáreas sembradas amenaza directamente la disponibilidad de alimentos básicos para la población. Anticipar las zonas y cultivos de alto riesgo es fundamental para la planificación de políticas públicas, la distribución de apoyos gubernamentales y el diseño de seguros agrícolas eficientes.

Objetivos de Análisis

El objetivo principal es aplicar técnicas de minería de datos para analizar patrones históricos y predecir el riesgo de pérdida de cultivos (área siniestrada) en México, con el fin de identificar las regiones y tipos de siembra más vulnerables, proporcionando información que apoye la toma de decisiones preventivas y la seguridad alimentaria en el sector agrícola.

De manera medible, esto se desglosa en múltiples metas técnicas que se abordarán en el proyecto:

1. **Análisis de Datos:** Identificar cómo ha evolucionado históricamente la pérdida de hectáreas en México entre 2010 y 2024, comparando la vulnerabilidad de las siembras de temporal frente a las de riego.
2. **Segmentar:** Agrupar los municipios del país en distintos perfiles de vulnerabilidad agrícola utilizando aprendizaje no supervisado. Se busca identificar clústeres de regiones que presenten comportamientos crónicos de pérdida frente a aquellas que muestran resiliencia, para entender sus características comunes.
3. **Predecir:** Entrenar modelos capaces de estimar la proporción de área siniestrada o clasificar el nivel de riesgo (alto/medio/bajo) de una futura

siembra, utilizando como variables predictoras el estado, el municipio, el tipo de cultivo, la modalidad (riego/temporal) y el ciclo agrícola.

Elección del Conjunto de Datos (*dataset*)

Para poder realizar el análisis de esta problemática se utilizaron los datos abiertos de la estadística de producción agrícola proporcionados por la Dirección General del Servicio de Información Agroalimentaria y Pesquera. Los datos que se proporcionan son a nivel municipal y a nivel nacional, para mayor detalle de análisis en este proyecto se consultaron los de nivel municipal en un periodo de tiempo que va desde 2010 hasta 2024.

La elección de estos datos nos ayuda en el desarrollo de los objetivos planteados, además de que fueron obtenidos a partir de una fuente gubernamental oficial que se basa en la realidad operativa del país. Además, cuenta con el información del registro de Área Sembrada, Área Siniestrada y variables de contexto crítico como la Modalidad (riego/temporal), el Cultivo y la ubicación geográfica hasta nivel Municipio.

Al abarcar 15 años continuos de registros, proporciona el volumen histórico necesario para que los algoritmos de minería de datos puedan encontrar patrones robustos a través del tiempo, capturando las variaciones climáticas de la última década a un nivel de detalle municipal.

CONCEPTOS Y CONTEXTO

Para interpretar correctamente los resultados del análisis es necesario comprender la terminología específica del sector agrícola mexicano utilizada en el dataset y a lo largo de este reporte.

Área sembrada Superficie agrícola en la que se depositó la semilla de un cultivo, previa preparación del suelo. Se mide en hectáreas y representa el punto de partida de cada ciclo productivo. No toda la superficie sembrada llega a producir: una parte puede cosecharse exitosamente y otra puede perderse por siniestro.

Área cosechada Fracción del área sembrada de la cual se obtuvo producción efectiva del cultivo. En condiciones normales, la mayor parte del área sembrada se cosecha; la diferencia entre ambas refleja las pérdidas ocurridas durante el ciclo.

Área siniestrada Superficie de la cual no se obtuvo producción debido a que el cultivo se perdió totalmente por alguna causa externa, ya sea climática (sequía, helada, granizo, inundación), biológica (plaga, enfermedad) u otra. Esta variable aplica únicamente a cultivos anuales, ya que los cultivos perennes (frutales, agave, caña) pueden recuperarse en el ciclo siguiente sin necesidad de resembrar.

Siniestro agrícola Evento que provoca la pérdida total o parcial de un cultivo antes de su cosecha. Los siniestros pueden ser de origen climático (el más común en México), biológico o accidental. En el contexto de seguros agrícolas, el siniestro es el evento que activa el pago de indemnización al productor.

Modalidad hídrica Clasificación de una siembra según su fuente de agua. Existen dos modalidades en el dataset:

- **Temporal:** la siembra depende exclusivamente de las precipitaciones naturales. Es la modalidad predominante en México en términos de superficie y la más vulnerable a variaciones climáticas.
- **Riego:** la siembra cuenta con infraestructura hídrica que permite suministrar agua de forma controlada (canales, presas, pozos, sistemas de goteo). Ofrece mayor resiliencia ante sequías pero no elimina completamente el riesgo de siniestro por heladas, plagas u otros factores.

Ciclo agrícola Periodo del año durante el cual se desarrolla un cultivo desde la siembra hasta la cosecha. El dataset registra tres ciclos:

- **Primavera-Verano:** el ciclo principal, que aprovecha las lluvias de mayo a octubre. Concentra la mayor parte de la agricultura de temporal y es el más expuesto al riesgo climático estacional.

- **Otoño-Invierno:** ciclo secundario que se desarrolla entre octubre y marzo, predominante en zonas de riego del noroeste del país donde las temperaturas lo permiten.
- **Perennes:** cultivos que no se ciñen a un ciclo anual específico porque su ciclo de vida supera el año (frutales, agave, caña de azúcar, café). Se registran de forma continua independientemente de la estación.

Distrito de Desarrollo Rural (DDR) Unidad administrativa de la Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación (SADER) que agrupa varios municipios con características productivas similares para fines de planificación y apoyo técnico.

Centro de Apoyo al Desarrollo Rural (CADER) Subdivisión del Distrito de Desarrollo Rural que opera a nivel local, brindando asistencia técnica y administrativa directamente a los productores.

Precio medio rural Precio promedio al que el productor vende su cosecha en el punto de origen, antes de cualquier proceso de transformación o comercialización. Se expresa en pesos por tonelada (o por la unidad de medida correspondiente al cultivo) y refleja el valor de mercado en condiciones normales de la región productora.

Rendimiento agrícola Producción obtenida por unidad de superficie cosechada, expresada generalmente en toneladas por hectárea. Es un indicador de la eficiencia productiva del cultivo en las condiciones específicas de ese año, región y modalidad. Valores bajos de rendimiento pueden indicar condiciones climáticas adversas, aunque no necesariamente implican siniestro total.

Seguridad alimentaria Condición en la que todas las personas tienen acceso físico, social y económico a alimentos suficientes, seguros y nutritivos que satisfacen sus necesidades. La pérdida de cultivos por siniestro amenaza directamente la seguridad alimentaria al reducir la disponibilidad de alimentos básicos y elevar sus precios.

Milpa Sistema agrícola tradicional mexicano basado en el cultivo simultáneo de maíz, frijol y calabaza en la misma parcela. Representa la base de la agricultura campesina de subsistencia en México y explica la alta correlación entre registros de maíz y frijol observada en el dataset.

DESCRIPCIÓN DEL DATASET

Fuente

Los datos abiertos en estadística de producción agrícola son proporcionados por la Dirección General del Servicio de Información Agroalimentaria y Pesquera (<https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php>). Se recopilieron los datos correspondientes al Nivel Municipal desde el año 2010 hasta el año 2014, esto nos da un volumen de **541,839 registros**, donde cada fila representa las estadísticas de producción agrícola para una combinación específica de año, ubicación, ciclo, modalidad de agua y cultivo.

Para obtener el conjunto de datos completo de las estadísticas en el sector agrícola fueron descargados los datasets correspondientes desde el año 2010 hasta el 2014. Para trabajar con la información completa se concatenaron todos estos datos.

Es importante mencionar que durante la concatenación de estos datos, algunos años cambiaban el nombre de las columnas, como por ejemplo Precio que llegó a registrarse como Preciomediorural. Para esto se unificaron estos nombres, que representan la misma información pero el sistema manejaba terminologías distintas.

Descripción de las Variables

Cada registro cuenta con 24 columnas que describen los detalles del mismo, estas son variables categóricas y numéricas.

Nombre de Variable	Descripción	Tipo
Anio	Año de la información.	Numérico
Idestado	Código que identifica a la entidad federativa o estado de producción.	Numérico
Nomestado	Nombre oficial de la entidad federativa o estado.	Categórico
Idddr	Código que identifica al Distrito de Desarrollo Rural.	Numérico
Nomddr	Nombre que identifica al Distrito de Desarrollo Rural.	Categórico

Idcader	Código que identifica al Centro de Apoyo al Desarrollo Rural.	Numérico
Nomcader	Nombre que identifica al Centro de Apoyo al Desarrollo Rural.	Categorico
Idmunicipio	Código que identifica al municipio o delegación de producción de cada entidad federativa.	Numérico
Nommunicipio	Nombre del municipio o delegación de producción.	Categorico
Idciclo	Código que identifica al ciclo agrícola.	Numérico
Nomcicloproductivo	Nombre del ciclo agrícola.	Categorico
Idmodalidad	Código que identifica al tipo de modalidad hídrica.	Numérico
Nommodalidad	Nombre de la modalidad hídrica que hace referencia a las vocaciones de la superficie, ya sean de temporal o de riego.	Categorico
Idunidadmedida	Código que identifica la unidad de medida.	Numérico
Nomunidad	Nombre que identifica la unidad de medida.	Categorico
Idcultivo	Código que identifica al cultivo agrícola.	Numérico
Nomcultivo	Nombre del cultivo agrícola.	Categorico
Sembrada	Es la superficie agrícola en la cual se deposita la semilla de cualquier cultivo, previa preparación del suelo (hectáreas).	Numérico
Cosechada	Es la superficie de la cual se obtuvo producción del cultivo indicado (hectáreas).	Numérico
Siniestrada	Es la superficie de la cual no se obtuvo producción debido a que se perdió por alguna causa, solo aplica para cultivos anuales, ya que los perennes se pueden recuperar las plantaciones en el año siguiente (hectáreas).	Numérico
Volumenproduccion	Volumen de producción de la superficie cosechada cuya unidad de medida son las	Numérico

	toneladas, con excepción del maguey pulquero y trigo ornamental, con una métrica de miles de litros y gruesas, respectivamente.	
Rendimiento	Rendimiento, la unidad de medida son toneladas por hectárea, con excepción de los cultivos que tienen otra métrica la cual se señala en el nombre del cultivo (gruesa, manojo, planta, entre otros).	Numérico
Precio	Precio medio rural, la unidad de medida son pesos por tonelada, con excepción de los cultivos que tienen otra métrica la cual se señala en el nombre del cultivo (gruesa, manojo, planta, entre otros).	Numérico
Valorproduccion	Valor expresado en pesos corrientes nacionales.	Numérico

LIMPIEZA Y PREPARACIÓN DE DATOS

Valores Faltantes


La siguiente tabla muestra los campos que cuentan con valores nulos en los registros.

	Nulos	% Nulos
Precio	487	0.09
Rendimiento	487	0.09
Volumenproduccion	1	0.00
Sembrada	2	0.00

Mediante el análisis de los registros se encontró que la calidad de los datos proporcionados por la Dirección General del Sistema de Información Agroalimentaria y Pesquera es consistente. La presencia de datos nulos para Precio y Rendimiento se encuentra en solo 487 registros, lo que representa un 0.09% de nuestro conjunto de datos. Estos registros son una pequeña proporción, dado que contamos con más de 500,000 datos resulta muy pequeña la cantidad de nulos.

Por otro lado, Volumenproduccion y Sembrada en conjunto presentan nulos en tan solo 3 registros, lo cual no afecta en la potencia estadística.

Resulta conveniente adentrarnos en la aparición de valores nulos en ciertos registros. En el siguiente gráfico podemos ver la correlación entre la presencia de nulos de las 4 variables que los presentan: Sembrada, Volumenproduccion, Rendimiento y Precio.



Podemos observar que Rendimiento y Precio están fuertemente relacionadas. En 487 registros, Precio y Rendimiento faltan en conjunto, es decir, cuando falta Precio siempre falta Rendimiento, lo que indica una regla o dependencia estricta.

Por otro lado, Sembrada y Volumenproduccion al ser muy pocos pueden ser considerados como errores de captura en el sistema de datos que obtuvimos inicialmente.

Adentrándonos más en la falta de los campos Precio y Rendimiento totalmente relacionados, encontramos que de los 487 registros sin Precio/Rendimiento, 487 (100.00%) tienen Área Cosechada igual a 0.

Si un cultivo se siembra pero hay una sequía o inundación y se pierde todo (Área Cosechada = 0), entonces el Volumen de Producción será 0. En este caso, la falta de datos es estructural y depende del área cosechada/siniestrada (esto lo clasifica como MAR, ya que la ausencia se explica por otra variable observable).

Decisiones sobre Valores Faltantes

1. Se eliminan los registros que tienen valores nulos en Sembrada y Volumenproduccion, debido a que indican presencia de errores de captura.
2. Para los 487 registros donde falta Precio/Rendimiento, se actualizan los campos correspondientes a 0 (cero), debido a que comprobamos que pudo haber sido error de captura cuando el área cosechada fue 0.

Registros Duplicados

En el total del conjunto de datos se encontraron únicamente 10 registros duplicados. Dado que es un número muy pequeño considerando el tamaño de datos que estamos trabajando, podemos eliminarlos sin afectar la potencia estadística.

Se eliminaron 10 registros duplicados y el dataset ahora tiene 541,829 filas.


Valores Atípicos

Para la identificación de valores atípicos se aplicó la regla IQR. Los resultados se complementan con boxplots comparativos por modalidad hídrica (Temporal vs. Riego).

	Q1	Q3	IQR	Límite inferior	Límite superior	% Outliers	% Outliers
Variable							
Sembrada	10.00	2.160000e+02	2.060000e+02	-2.990000e+02	5.250000e+02	86182	15.91
Cosechada	9.00	2.000000e+02	1.910000e+02	-2.775000e+02	4.865000e+02	86336	15.93
Siniestrada	0.00	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	26817	4.95
Volumenproduccion	52.40	1.743753e+03	1.691352e+03	-2.484629e+03	4.280781e+03	85197	15.72
Rendimiento	2.07	2.000000e+01	1.793000e+01	-2.482500e+01	4.689500e+01	48834	9.01
Precio	2217.22	7.675000e+03	5.457780e+03	-5.969450e+03	1.586167e+04	39129	7.22
Valorproduccion	246245.25	5.443200e+06	5.196955e+06	-7.549187e+06	1.323863e+07	81976	15.13

Se decidió agrupar los gráficos por modalidad hídrica (“Riego” vs “Temporal”) en lugar de hacerlo de manera general debido a que tienen perfiles y escalas muy diferentes.


Área Sembrada y Cosechada



Ambas variables presentan un porcentaje de outliers elevado y prácticamente idéntico. Los valores que superan estos umbrales corresponden a grandes unidades productivas en entidades donde la agricultura comercial a gran escala es predominante. En los gráficos se observa que la modalidad Temporal concentra los outliers de mayor magnitud absoluta, mientras que Riego presenta outliers más acotados pero igualmente presentes. Esta asimetría refleja que las grandes superficies de temporal corresponden a regiones donde un solo registro puede representar miles de hectáreas de un solo cultivo en un municipio.

Estos outliers no se eliminan. Representan realidades productivas legítimas y su exclusión sesgaría el análisis hacia pequeños productores, perdiendo información crítica sobre las regiones de mayor impacto en la seguridad alimentaria nacional.

Área Siniestrada




Siniestrada presenta una situación estadísticamente particular: tanto Q1, Q3 como el IQR son iguales a cero, lo que resulta en límites inferior y superior de exactamente 0. Bajo la regla IQR estricta, cualquier valor mayor a cero sería técnicamente un outlier. Sin embargo, esto refleja la naturaleza del fenómeno, pues más del 75% de los registros no reportan siniestro alguno, por lo que la distribución está concentrada en cero. Los 26,817

registros clasificados como outliers (4.95%) son precisamente los eventos de pérdida real.


Se aprecia que los siniestros de mayor magnitud ocurren predominantemente en la modalidad Temporal. La modalidad de Riego también presenta outliers, pero de menor escala, consistente con su mayor resiliencia ante variaciones climáticas.

Volumen y Valor de Producción




Ambas variables presentan porcentajes de outliers altos (15.72% y 15.13% respectivamente). En ambas variables la modalidad Riego concentra los valores más extremos en el extremo superior, pues la agricultura de riego tiende a producir cultivos de mayor valor comercial y mayor rendimiento por hectárea (hortalizas, berries, aguacate), generando registros de producción y valor considerablemente más altos que los cultivos de temporal.

Rendimiento



El 9.01% de los registros de Rendimiento son outliers, con un límite superior de 46.9 unidades y un máximo registrado de 10,598,037. Como se mencionó en las estadísticas descriptivas, algunos cultivos del dataset utilizan unidades de medida distintas a toneladas por hectárea (miles de litros, gruesas, manojos), lo que hace que sus valores de rendimiento sean numéricamente incomparables con el resto.

Precio



Con un 7.22% de outliers y un máximo de 2,048,000 pesos por tonelada, Precio refleja la enorme heterogeneidad de cultivos en el dataset. Los precios más extremos corresponden a productos de nicho o alta especialización (flores, especias, cultivos orgánicos certificados), que coexisten con granos básicos de bajo precio unitario como el maíz o el frijol. Los boxplots muestran que ambas modalidades presentan outliers similares en magnitud, aunque Riego tiene

una dispersión ligeramente mayor, consistente con la mayor diversidad de cultivos de alto valor que se producen bajo esta modalidad.

Decisiones en Valores Atípicos

En ninguna variable se justifica la eliminación de outliers, dado que todos corresponden a fenómenos reales y documentables del sistema agrícola mexicano. La estrategia general adoptada es la conservación con transformación, debido a que se busca caracterizar los extremos del sistema: las pérdidas más severas, las regiones más vulnerables y los cultivos de mayor riesgo.

Transformaciones Aplicadas

A partir de la información obtenida a través del dataset realizamos la creación de una nueva variable: Proporción de Siniestro. Esto debido a que la columna Siniestrada registra las hectáreas de la superficie de la cual no se obtuvo cultivo debido a alguna causa de fuerza mayor como lo es el impacto del cambio climático. Sin embargo, podemos diferenciar en que perder 500 hectáreas en un municipio que sembró 600 representa una catástrofe agrícola, mientras que la misma cifra en un municipio que sembró 50,000 hectáreas constituye una pérdida marginal.


Por ello, este ratio nos permite tener más consistencia de análisis y dimensionar mejor. El rango va de 0 (sin pérdida) a 1 (la totalidad del área sembrada fue siniestrada). La definición de la variable es:

$$proporcion_siniestro = \frac{Siniestrada}{Sembrada}$$

Como resultado obtenemos la asignación de esta nueva variable para los registros, tenemos asignada esta proporción para los 541,839 datos.

Para facilitar el análisis de esta variable, la variable continua `proporcion_siniestro` se discretiza en 5 niveles de riesgo agrícola.

- **Sin siniestro** (= 0): ninguna pérdida registrada
- **Riesgo bajo** (0–10%): pérdida marginal, sin impacto productivo relevante
- **Riesgo medio** (10–40%): pérdida moderada con reducción de rendimiento
- **Riesgo alto** (40–75%): pérdida severa que compromete el ciclo
- **Pérdida crítica** (>75%): pérdida casi total del área sembrada



A partir de la distribución de esta variable observamos un desbalance muy grande, pues de las categorías definidas, 'Sin siniestro' es la que domina en el conjunto de datos. Esta categoría acumula la mayor parte de la información, lo que resalta el hecho de que si queremos predecir si ocurrirá un siniestro en un cultivo debemos balancear las clases para tener mejores resultados y no sesgar el modelo al entrenarlo.

ANÁLISIS EXPLORATORIO

Estadísticas Descriptivas de Variables Numéricas y Categóricas

Variables Numéricas

El análisis descriptivo de las variables numéricas revela patrones relevantes sobre la estructura productiva y la distribución del riesgo agrícola en México durante el periodo 2010–2024.

	mean	std	25%	50%	75%
Sembrada	5.807369e+02	2.640830e+03	10.00	39.40	2.160000e+02
Cosechada	5.442921e+02	2.535063e+03	9.00	35.00	2.000000e+02
Siniestrada	2.413520e+01	3.866740e+02	0.00	0.00	0.000000e+00
Volumenproduccion	1.619187e+04	6.179774e+05	52.40	292.50	1.743753e+03
Rendimiento	1.091273e+03	6.211413e+04	2.07	7.91	2.000000e+01
Precio	6.783825e+03	1.171066e+04	2217.22	4298.52	7.675000e+03
Valorproduccion	1.617641e+07	9.034843e+07	246245.25	1084183.48	5.443200e+06

	min	max	rango
Sembrada	0.0	2.165483e+05	2.165483e+05
Cosechada	0.0	2.165483e+05	2.165483e+05
Siniestrada	0.0	5.407300e+04	5.407300e+04
Volumenproduccion	0.0	1.183000e+08	1.183000e+08
Rendimiento	0.0	1.059804e+07	1.059804e+07

Precio	0.0	2.048000e+06	2.048000e+06
Valorproduccion	0.0	7.622198e+09	7.622198e+09

Área sembrada y cosechada presentan distribuciones muy similares entre sí, lo cual es esperado dado que la mayor parte de lo sembrado logra cosecharse en condiciones normales. Ambas variables tienen una media considerablemente mayor a su mediana (Sembrada: media = 580.7 ha, mediana = 39.4 ha; Cosechada: media = 544.3 ha, mediana = 35.0 ha), lo que indica una distribución fuertemente sesgada hacia la derecha. Esto refleja la coexistencia de pequeños productores con superficies mínimas junto a grandes unidades productivas que elevan la media. El valor máximo de 216,548 ha confirma la presencia de registros de gran escala que actúan como outliers en la distribución.

La media de **Área siniestrada** es de apenas 24.1 ha, pero su desviación estándar es de 386.7 ha, casi 16 veces mayor que la media, lo que evidencia una dispersión extrema. Más revelador aún es que tanto el percentil 25 como el percentil 50 y el percentil 75 son iguales a 0, lo que significa que al menos el 75% de los registros no reportaron ningún siniestro. La pérdida agrícola es entonces un evento infrecuente pero de alta magnitud cuando ocurre, con un máximo registrado de 54,073 ha en un solo registro.

Por otro lado, **Rendimiento** presenta la mayor dispersión relativa de todas las variables, con una desviación estándar de 62,114 sobre una media de 1,091 ton/ha, y un máximo de 10,598,037. La unidad de medida son toneladas por hectárea, con excepción de los cultivos que tienen otra métrica la cual se señala en el nombre del cultivo (gruesa, manojo, planta, entre otros). Por lo que los valores extremos pueden corresponder a estas medidas distintas.

Precio y Valorproduccion muestran rangos enormes (precio máximo de 2,048,000 pesos por tonelada), consistentes con la diversidad de cultivos registrados, desde granos básicos de bajo valor unitario hasta productos especializados de alto valor. Para el Precio encontramos que el valor mínimo corresponde a 0, pues puede ser que no se haya cosechado nada o que los cultivos sean de autoconsumo y no registra precio comercial.

Variables Categóricas

- **Estado:** 33 categorías. **Moda:** 'Oaxaca'

Nomestado registra 33 categorías con moda en Oaxaca con 71,184 registros, lo que indica que este estado concentra la mayor cantidad de registros en el dataset. Esto es consistente con su alta diversidad municipal (es el estado con más municipios en México, 570) y con la variedad de cultivos que se producen en su

territorio. No implica necesariamente que Oaxaca tenga el mayor volumen productivo, sino que tiene la mayor cantidad de combinaciones únicas de año-municipio-cultivo registradas. Sin embargo, el estado tiene una importante producción agrícola, en su territorio se siembra: maíz, frijol, cacahuate, trigo, sorgo, café, limón, mango, maguey mezcalero (que es la bebida tradicional de la región), copra y hule, siendo éstos los cultivos más representativos. Además cuenta con frutales que le han dado fama a Oaxaca, por ejemplo la piña de Loma Bonita y el chicozapote de la región de la Cañada.

- **Ciclo Productivo:** 3 categorías. **Moda:** 'Primavera-Verano'

Nomcicloproductivo tiene 3 categorías con moda en Primavera-Verano, el ciclo agrícola principal en México. Este ciclo concentra la mayoría de la actividad de temporal, que depende de las lluvias estacionales y es por tanto el más expuesto al riesgo climático. Su predominancia en el dataset es relevante para el análisis de siniestros, ya que las sequías e inundaciones afectan principalmente este ciclo. Las categorías para el ciclo productivo son: Primavera-Verano, Otoño-Invierno y Perennes. La que tiene menos frecuencia es Otoño-Invierno, lo que puede deberse a las dificultades climáticas de la temporada para ciertos cultivos.

- **Modalidad:** 2 categorías. **Moda:** 'Riego'


Nommodalidad presenta únicamente 2 categorías (Riego y Temporal), con moda en Riego. Aunque en la realidad nacional la agricultura de temporal supera en superficie a la de riego, el mayor número de registros bajo modalidad de riego puede explicarse por la mayor diversidad de cultivos que se producen bajo esta modalidad y su distribución en más municipios. Esta variable es una de las más importantes para el análisis de vulnerabilidad, dado que las siembras de temporal son estructuralmente más susceptibles al siniestro por su dependencia de las precipitaciones.

- **Cultivo:** 454 categorías. **Moda:** 'Maíz grano'

Nomcultivo es la variable categórica con mayor cardinalidad, con 454 categorías distintas y moda en Maíz grano. La dominancia del maíz es consistente con su rol como cultivo básico de México: es el de mayor superficie sembrada, el más distribuido geográficamente y el de mayor relevancia para la seguridad alimentaria nacional. A nivel mundial, México es el 7° productor de este grano.

Distribuciones de Variables Numéricas

A continuación se presentan las distribuciones de cada una de nuestras variables numéricas a partir de las cuales realizamos observaciones basadas en nuestro contexto.



- **Sembrada y Cosechada**

Ambas variables presentan distribuciones notablemente similares en forma, lo cual es coherente con su relación estructural: en condiciones normales, la mayor parte de lo sembrado termina siendo cosechado. La cola derecha corresponde a las grandes superficies comerciales identificadas en el análisis de outliers.

La similitud entre ambas distribuciones confirma que el dataset no presenta inconsistencias estructurales entre área sembrada y cosechada, y que la diferencia entre ambas es un fenómeno minoritario pero presente a lo largo de todo el rango de escala productiva.

- **Siniestrada**

La gran mayoría de los registros no reportan pérdida alguna. Esta forma de distribución tiene implicaciones directas para el modelado. Un modelo de regresión convencional tendrá dificultades para ajustarse correctamente a esta estructura, ya que intentará predecir un valor continuo en una distribución donde el 75% de las observaciones son exactamente cero. Esto refuerza la decisión de plantear el problema supervisado como una clasificación binaria (siniestro / no siniestro) o, alternativamente, como un modelo en dos etapas: primero clasificar si habrá siniestro, y luego estimar su magnitud únicamente sobre los registros positivos.

- **Volumen de Producción**

Volumenproduccion presenta la distribución más cercana a una normal aproximada de todas las variables. Existe una pequeña masa cercana a 0 que corresponde a registros sin producción (parcelas cosechadas con pérdida total o errores en la captura).

- **Rendimiento**

La distribución es bimodal con sesgo positivo marcado. Se observa una cola extremadamente larga que se extiende, correspondiente a los valores de

rendimiento en unidades no estándar identificados en el análisis de outliers. Esta bimodalidad puede estar reflejando dos poblaciones distintas dentro del mismo dataset: cultivos medidos en toneladas por hectárea y cultivos medidos en otras unidades, cuyos valores numéricos son órdenes de magnitud mayores.

- **Precio**

Precio presenta la distribución más claramente bimodal del conjunto, refleja la coexistencia de dos grupos de cultivos con estructuras de precio fundamentalmente distintas: por un lado, granos básicos de bajo precio unitario (maíz, sorgo, frijol) y por otro, productos hortícolas, frutícolas y especializados de alto valor comercial. La separación clara entre ambas modas sugiere que Precio podría ser una variable útil para capturar la diferencia entre agricultura de subsistencia y agricultura comercial.


- **Valor de Producción**

Valorproduccion presenta la distribución más cercana a una campana simétrica, con la masa principal concentrada equivalente a valores de producción de entre 60,000 y 8,900,000 pesos por registro. Este rango representa la actividad económica agrícola típica a nivel municipal en México: desde pequeñas unidades productivas con ventas anuales de decenas de miles de pesos hasta operaciones medianas con ingresos de varios millones.

La barra de la izquierda corresponde a registros con valor de producción igual a cero, asociados principalmente a parcelas siniestradas en su totalidad donde no hubo cosecha que comercializar, o a registros con precio no disponible que impidieron el cálculo del valor.

Matriz de Correlaciones

Para analizar las relaciones entre las variables numéricas del dataset se calculó la matriz de correlaciones de Spearman, ya que mide la correlación entre los rangos de los valores en lugar de los valores directos, lo que la hace robusta ante distribuciones asimétricas y valores atípicos extremos como los identificados en las secciones anteriores.




A partir del gráfico podemos realizar las siguientes observaciones relevantes:

- La correlación más alta del dataset, prácticamente perfecta, se da entre Sembrada y Cosechada. Esto nos indica que en la gran mayoría de los ciclos agrícolas, lo que se siembra termina siendo cosechado. La pequeña diferencia entre ambas variables es precisamente el espacio donde ocurre el siniestro.
- Las correlaciones positivas entre las variables de área (Sembrada y Cosechada) y el volumen de producción indican que a mayor superficie cosechada, mayor volumen producido. La correlación es ligeramente más fuerte con Cosechada (0.79) que con Sembrada (0.75), lo que tiene sentido porque el volumen de producción depende del área efectivamente cosechada, no del área inicialmente sembrada. Esta relación no es perfecta porque el rendimiento por hectárea varía considerablemente entre cultivos, regiones y años, introduciendo variabilidad que rompe la proporcionalidad directa.
- Un mayor rendimiento por hectárea se asocia con mayor volumen de producción, aunque la relación no es tan fuerte como cabría esperar porque el volumen también depende de la superficie cultivada. Municipios con rendimientos altos pero superficies pequeñas pueden tener volúmenes similares a municipios con rendimientos bajos pero grandes extensiones, esto debido al valor que tiene cada tipo de cultivo.
- Observamos correlaciones negativas moderadas para el Precio que revelan un patrón económico: los cultivos de mayor precio unitario tienden a producirse en menores volúmenes y con menores rendimientos en hectáreas. Los cultivos básicos de alto volumen como el maíz tienen precios bajos por tonelada, mientras que los productos como flores o especias tienen precios altos pero se producen en superficies pequeñas y con rendimientos acotados.

- El hallazgo más relevante para el objetivo del proyecto es que Siniestrada presenta correlaciones cercanas a cero con todas las demás variables. Ninguna variable numérica del dataset tiene una relación lineal con el área siniestrada. Esto puede indicar que el siniestro es un fenómeno multifactorial y no lineal.

Relación entre Área Sembrada y Área Siniestrada

La siguiente gráfica muestra la relación entre el área sembrada y el área siniestrada para una muestra aleatoria de 50,000 registros, diferenciando por modalidad hídrica.



El rasgo más dominante de la gráfica es la línea horizontal densa que se extiende a lo largo de todo el rango del eje horizontal. Esta línea representa todos los registros donde no hubo siniestro alguno, independientemente de la superficie sembrada. La gran mayoría de las siembras concluyen sin pérdida, sin importar si son de temporal o de riego ni cuál sea su escala.

Los registros con siniestro distinto de cero forman una nube de puntos delimitada por una diagonal superior que representa el límite físico del problema, que es que el área siniestrada no puede superar el área sembrada. Los puntos que se acercan a la diagonal son registros donde prácticamente la totalidad de lo sembrado se perdió, es decir, siniestros totales o casi totales. Los puntos en la parte inferior del triángulo representan siniestros parciales, donde solo una fracción del área sembrada se vio afectada.


Dentro de la nube de siniestros, se observa que la modalidad temporal alcanzan valores más altos en el eje vertical que la de riego. Los puntos de Riego también alcanzan valores altos pero con menor frecuencia en los extremos superiores. Esto puede indicar que la agricultura de modalidad temporal es estructuralmente más

vulnerable al siniestro que la de riego, tanto en frecuencia como en magnitud de la pérdida. La dependencia de las lluvias en el temporal lo expone directamente a sequías, heladas e inundaciones, mientras que la infraestructura hídrica del riego actúa como amortiguador ante estas variaciones climáticas.

Tendencias en Variables Categóricas


Dentro de las variables categóricas encontramos: “Nomestado”, “Nomcicloproductivo”, “Nommodalidad”, “Nomcultivo”. A continuación se presentan los gráficos de las frecuencias en las categorías para cada una de estas variables.

Estado




En la distribución de registros por estado Oaxaca encabeza el ranking con aproximadamente 70,000 registros. Oaxaca es el estado con mayor número de municipios en México, lo que multiplica directamente la cantidad de combinaciones posibles en el dataset. Además, su alta diversidad climática y cultural se traduce en una gran variedad de cultivos registrados, desde maíz y frijol en las sierras hasta café, cacao y frutas tropicales en las costas y valles. Su presencia dominante en el dataset no implica que sea el mayor productor en volumen o valor, sino el de mayor diversidad de registros agrícolas.

Ciclo Productivo




El dataset se distribuye entre tres ciclos agrícolas con frecuencias relativamente equilibradas, aunque Primavera-Verano es el predominante con aproximadamente 230,000 registros. Este ciclo concentra la mayor actividad agrícola del país porque coincide con la temporada de lluvias, que alimenta directamente la agricultura de temporal. La predominancia del ciclo Primavera-Verano es relevante para el análisis de siniestros porque es precisamente el ciclo más expuesto a fenómenos climáticos extremos como sequías e inundaciones durante la temporada de lluvias.

Modalidad Hídrica



La distribución entre Riego y Temporal es equilibrada, lo cual se explica porque la agricultura de riego, al permitir múltiples ciclos productivos al año y una mayor diversidad de cultivos, genera más combinaciones únicas de registro que la agricultura de temporal.

Cultivos




El ranking de cultivos confirma la centralidad del Maíz grano en la agricultura mexicana. Su presencia masiva refleja que se cultiva prácticamente en todos los estados, municipios, ciclos y modalidades del país, siendo el alimento base de la dieta mexicana y el cultivo de subsistencia. El Frijol ocupa el segundo lugar con


cerca de 43,000 registros, consolidando junto al maíz el binomio tradicional de la milpa mexicana.

A partir del tercer lugar la frecuencia cae abruptamente: Avena forrajera en verde, Pastos y praderas y Tomate rojo (jitomate) rondan los 18,000–21,000 registros, seguidos por Sorgo grano, Chile verde, Tomate verde y Calabacita con entre 10,000 y 15,000 registros. La presencia de varios cultivos forrajeros (avena, pastos, sorgo forrajero, maíz forrajero, alfalfa) entre los más frecuentes refleja la importancia de la ganadería como actividad complementaria a la agricultura en muchas regiones del país.

Cultivos más frecuentes en los Estados más frecuentes



El patrón más evidente es la concentración extrema en Oaxaca con maíz grano (17,757 registros) y frijol (11,919 registros). Estos dos valores por sí solos representan una proporción desproporcionada del total, lo que confirma que la combinación Oaxaca-maíz es el eje central alrededor del cual está construido el dataset.




Por otro lado, tenemos los registros por cultivo en los Top 5 estados. La barra azul de Oaxaca domina visualmente en maíz y frijol, duplicando o triplicando a cualquier otro estado en ambos cultivos. Esta asimetría visual refuerza el punto señalado anteriormente: el dataset tiene un sesgo estructural hacia Oaxaca en los cultivos básicos. Para los tres cultivos restantes la distribución entre estados es más equilibrada, con barras de altura similar entre Puebla, Michoacán, Jalisco y Veracruz.

Cultivos a lo largo del tiempo

Las visualizaciones de series de tiempo permiten examinar la dimensión temporal del dataset, que abarca 15 años continuos de actividad agrícola (2010–2024). La perspectiva temporal es fundamental para el objetivo del proyecto porque el riesgo de siniestro no es un fenómeno estático: está determinado en parte por condiciones climáticas que varían año con año y que han mostrado una tendencia de intensificación asociada al cambio climático.

Evolución Anual




La gráfica muestra la evolución de las tres variables de área a nivel nacional en millones de hectáreas para el periodo 2010–2024.

Área sembrada y cosechada muestran un comportamiento relativamente estable durante la primera mitad del periodo. A partir de 2019 se observa una caída pronunciada y sostenida que lleva ambas variables a su mínimo histórico en 2020–2021, con aproximadamente 18 millones de hectáreas sembradas y 17 millones cosechadas. Esta caída coincide con el periodo de pandemia por COVID-19, que afectó severamente las cadenas de suministro agrícola, el acceso a insumos y la disponibilidad de mano de obra en el campo mexicano. A partir de 2022 se observa una recuperación gradual, aunque sin recuperar los niveles máximos previos a 2019. La brecha persistente entre Sembrada y Cosechada a lo largo de todo el periodo refleja la pérdida estructural que ocurre en cada ciclo, compuesta tanto por siniestros como por abandono de parcelas y otros factores no climáticos.

El año de mayor siniestro en todo el periodo es 2011. Este año es ampliamente documentado como uno de los más severos en términos de sequía en México: la sequía de 2011 fue considerada la peor en décadas. Tras este pico, el área siniestrada cae drásticamente en 2012 y se mantiene en niveles bajos durante la mayor parte del resto del periodo, con un repunte moderado en 2023 que sugiere un nuevo episodio de condiciones climáticas adversas.


Área Siniestrada Anual por Modalidad Hídrica



Podemos observar como la modalidad Temporal domina completamente el siniestro en todos los años del periodo. En 2011, su pico más alto representa más de cuatro veces el valor de riego en ese mismo año. Esta diferencia es muestra que cuando ocurre una sequía severa, son las parcelas que dependen exclusivamente de la lluvia las que sufren las pérdidas más devastadoras, mientras que las de riego cuentan con infraestructura hídrica que mitiga parcialmente el impacto.

La modalidad Riego presenta una línea considerablemente más baja y estable a lo largo de todo el periodo. Si bien el riego no es inmune al siniestro, su exposición al riesgo climático es significativamente menor.

Área Siniestrada por Estado




El ranking revela que el riesgo agrícola en México tiene una geografía claramente definida hacia el norte y el Altiplano Central. San Luis Potosí y Zacatecas encabezan la lista con 1.75 y 1.6 millones de hectáreas perdidas acumuladas, seguidos por Tamaulipas (1.3 millones) y Sinaloa (1.05 millones). Los cuatro estados del top tienen en común grandes superficies de temporal expuestas a sequías recurrentes, y concentran prácticamente el doble de siniestros que cualquier estado del tercio inferior del ranking.

En contraste, estados como Oaxaca, Puebla o Jalisco (que lideraban el número de registros totales en el dataset) aparecen aquí con valores relativamente bajos, confirmando que tener muchos registros no equivale a tener alto riesgo.

Estados con mayor Área Cosechada por Modalidad Hídrica

El siguiente gráfico muestra la superficie cosechada acumulada (2010–2024) por modalidad hídrica para los diez estados más productivos, permitiendo identificar tanto el volumen total como la composición interna de cada entidad.



Jalisco, Veracruz y Chiapas encabezan el ranking y los tres presentan una composición dominada por la modalidad temporal. Esto refleja que su alta productividad está sostenida principalmente por la agricultura dependiente de lluvias, lo que implica una exposición estructural al riesgo climático pese a no aparecer en el top de siniestros por sus condiciones climáticas relativamente favorables

En Sinaloa, vemos como la porción de riego supera ampliamente al temporal. Los grandes distritos de riego del norte sustentan una producción comercial intensiva de trigo, maíz, soya y hortalizas de exportación, por lo que presenta mayores avances hidroagrícolas.

Podemos ver que a pesar de que Oaxaca es el estado con más registros, no es el que tiene mayor área cosechada, sin embargo, su presencia en el ranking muestra su importancia en su aporte a la agricultura del país. Presenta casi la totalidad de su superficie cosechada bajo modalidad temporal, con una porción de riego mínima, lo que es coherente con su perfil de agricultura campesina de pequeña escala en zonas de difícil acceso donde la infraestructura hídrica es escasa.

Los estados con temporal casi exclusivo pero condiciones climáticas favorables (Jalisco, Veracruz, Chiapas, Oaxaca) cosechan mucho sin perder proporcionalmente, validando que la modalidad hídrica interactúa con la geografía climática para determinar el riesgo real.

CLUSTERING, K-MEANS

Objetivo del agrupamiento

El objetivo del agrupamiento no supervisado es segmentar los 2,458 municipios en productores de México en perfiles diferenciados de vulnerabilidad agrícola, utilizando únicamente las características estructurales de cada municipio, como la escala productiva, riesgo histórico, dependencia hídrica, productividad, valor comercial y diversificación. A diferencia del modelo supervisado que busca predecir el siniestro a nivel cultivo, el clustering identifica patrones territoriales latentes que explican porqué ciertos municipios son crónicamente más vulnerables que otros, independientemente del cultivo específico o del año. Esta definición es fundamental porque un municipio puede tener baja siniestralidad en un año particular pero ser estructuralmente frágil debido a su dependencia del temporal, su baja diversificación o se escasa infraestructura hídrica.

La segmentación obtenida permite:

1. **Focalizar políticas públicas:** Los perfiles identificados permiten priorizar qué municipios requieren inversión urgente en infraestructura hídrica, seguros agrícolas paramétricos o programas de apoyo directo al productor.
2. **Diseñar estrategias diferenciadas:** Cada segmento de vulnerabilidad requiere un enfoque distinto. Un municipio de temporal con alta siniestralidad crónica necesita intervenciones distintas a uno de riego tecnificado con bajo riesgo.
3. **Complementar el modelo supervisado:** Mientras el modelo predictivo responde "¿qué cultivo tiene alto riesgo este ciclo?", el clustering responde "¿qué municipios son estructuralmente vulnerables sin importar el cultivo?". La combinación de ambas perspectivas ofrece una visión integral del riesgo agrícola nacional.

Fundamentos Teóricos del Agrupamiento

Aprendizaje No Supervisado y Particionamiento

El aprendizaje no supervisado opera sobre datos sin etiquetas previas. Su meta es descubrir estructura latente a partir de la geometría de los atributos. El particionamiento divide el espacio de observaciones en k grupos mutuamente excluyentes, donde cada punto pertenece a exactamente un grupo, lo que se conoce

como hard clustering, a diferencia del soft clustering donde un punto puede pertenecer parcialmente a varios grupos.

K-Means es el algoritmo de hard clustering por excelencia. Su elección para este proyecto se justifica por cuatro razones:

1. Las seis variables de agrupamiento son continuas, lo que hace que el centroide (media aritmética multivariada) sea una representación geométrica válida del grupo.
2. Se busca una partición plana, no jerárquica, que sea directamente interpretable y accionable para el diseño de políticas públicas.
3. La escala del problema de 2,458 municipios resulta computacionalmente trivial para K-means.
4. Tras aplicar la transformación logarítmica, los datos no representan formas de cluster extremadamente irregulares que requieren algoritmos basados en densidad como DBSCAN.

Representación Vectorial y Métrica de Proximidad

Cada municipio se representa como un vector $x \in \mathbb{R}^6$, donde cada dimensión corresponde a una de las seis variables de agrupamiento. La similitud entre dos municipios se mide con la distancia euclidiana:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Esta métrica es sensible a la escala de las variables, razón por la cual la estandarización previa es obligatoria. Sin ella una variable de magnitud grande como la superficie sembrada en hectáreas dominaría el cálculo de las distancias y haría prácticamente invisible la diferencia en proporciones de siniestro, cuyo rango es de 0 a 1.

Centroide y Función Objetivo

El centroide μ_j de un clúster C_j es el punto de menor distancia media del resto del grupo, calculado como la media aritmética multivariada de todos los puntos asignados:

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

K-Means minimiza la inercia o Suma de Errores al Cuadrado (SSE), que cuantifica la dispersión interna total de todos los clústeres:

$$J = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$


El objetivo es que $J \rightarrow 0$: puntos muy cercanos a su centroide. Dado que encontrar la partición global óptima es un problema NP-Hard, K-Means utiliza la heurística iterativa del Algoritmo de Lloyd.

Heurística del Algoritmo de Lloyd

El algoritmo opera en cuatro pasos iterativos. En la inicialización con K-Means ++, se selecciona el primer centroide aleatoriamente y los siguientes $k - 1$ se eligen con probabilidad proporcional $d(x, \mu_{\text{más cercano}})^2$, forzando que los centroides iniciales estén bien separados y acelerando la convergencia. En el paso de asignación, cada municipio x_i , se asigna al clúster cuyo centroide esté a menor distancia euclidiana, definiendo particiones poligonales conocidas como Diagramas de Voronoi:

$$C_j = \{\|x_i - \mu_j\|^2 \leq \|x_i - \mu_l\|^2, \forall l \neq j\}$$

En el paso de actualización, se recalcula cada centroide como la media de los puntos ahora asignados a ese clúster. Finalmente, el criterio de convergencia detiene el proceso cuando las asignaciones no cambian, la inercia deja de decrecer o se alcanza el número máximo de iteraciones. El resultado es un óptimo local garantizado. Por ello se ejecutaron múltiples inicializaciones y se retuvo la de menor inercia final.



Se muestra la proyección de los 2,458 municipios sobre las dos primeras componentes principales, junto con los centroides finales de K-Means. Las regiones de Voronoi formadas por estos centroides particionan el espacio. El clúster vulnerabilidad crítica aparece visiblemente separado en el extremo del eje PC1, reflejando su perfil atípico.

Preparación de los datos para el agrupamiento

Agregación a nivel municipal

El dataset original contiene 541,829 registros a nivel cultivo-municipi-año. Para aplicar clustering es necesario agregar los datos a nivel municipal, ya que la vulnerabilidad estructural como la dependencia de temporal, escala productiva, diversificación es una propiedad del territorio, no una combinación específica de cultivo y año.

La agregación se realizó mediante los siguientes pasos:

1. Agrupación por municipio: se combinaron todos los registros de cada municipio utilizando Nomestado y Nommunicipio como claves de agrupación.
2. Suma de hectáreas: se sumaron Sembrada, Siniestrada, Cosechada, Area-temporal-total, Volumenproduccion y Valorproduccion a nivel municipal.
3. Promedios: se calcularon los promedios de Precio-medio, Rendimiento_medio y Diversidad_cultivos (número de cultivos únicos por municipio).
4. Filtrado: se excluyeron municipios con Sembrada_total < 0.1 hectáreas ya que se consideraron como inactivos.

Variables seleccionadas

Se seleccionaron 6 variables agregadas, cada una representando un aspecto estructural del perfil agrícola municipal.

Variable	Definición	Justificación
log_Sembrada_total	Logaritmo de la superficie total sembrada en hectáreas	Distingue entre municipios de agricultura a gran escala versus agricultura familiar o subsistencia
proporcion_siniestro_total	Proporcion de hectáreas siniestradas respecto a las sembradas (Siniestrada_total / Sembrada_total)	Variable central de riesgo histórico ya que captura la vulnerabilidad del municipio frente a eventos climáticos

prop_temporal	Proporción del área sembrada bajo la modalidad de temporal(Area_temporal_total/Sembrada_total)	Refleja la exposición climática ya que la agricultura de temporal depende de lluvias naturales, lo que la hace más vulnerable
log_Rendimiento_medio	Logaritmo del rendimiento promedio, toneladas por hectárea	Identifica la eficiencia productiva de la tierra ya que los rendimientos bajos sugieren limitaciones estructurales
log_Precio_medio	Logaritmo del precio medio rural, pesos por tonelada	Refleja el valor comercial de la producción pues los cultivos de alto precio suelen asociarse a agricultura más tecnificada
log_Diversidad_cultivos	Logaritmo del número de cultivos únicos registrados en el municipio	La diversidad del cultivo es una estrategia de mitigación de riesgos; municipios monocultivo son más vulnerables.

Transformaciones y escalado

Cuatro de las seis variables seleccionadas (Sembrada_total, Rendimiento_medio, Precio_medio y Diversidad_cultivos) presentan distribuciones fuertemente sesgadas a la derecha donde unos pocos municipios de gran escalada dominan los valores máximos mientras la mayoría se concentra en rangos bajos. Por ejemplo, la superficie sembrada promedio por municipio es de 580 hectareas, pero existen municipios que superan las 200,000 hectáreas.

Para mitigar este sesgo y estabilizar la varianza, se aplicó la transformación logarítmica $f(x) = \ln(1 + x)$ a las siguientes variables:

- log_Sembrada_total
- log_Rendimiento_medio
- log_Precio_medio
- log_Diversidad_cultivos

La razón por la cual se suma un + 1 garantiza que los valores igual a cero no generen valores indefinidos. Esta transformación comprime la escala de los extremos sin eliminarlos, preservando la información sobre las regiones de alta productividad o alto valor comercial.

Posteriormente se aplicó estandarización con StandarScaler, que transforma cada variable a media 0 y desviación estándar 1:

$$Z_i = \frac{x_i - \mu}{\sigma}$$

Este paso resulta obligatorio para K-Means porque el algoritmo calcula distancias euclidianas entre puntos. Sin estandarización las variables de mayor magnitud dominarían el cálculo y harían invisibles las diferencias en variables acotadas como `proporcion_siniestro_total` (rango 0-1). La transformación logarítmica previa reduce el impacto de los valores extremos documentados en el EDA, de modo que el `StandardScaler` posterior actúa sobre una distribución ya comprimida y la estandarización resulta efectiva.

Selección del Número Óptimo de Clústeres

Para determinar el valor óptimo de k se aplicaron dos criterios complementarios evaluando K-Means en el rango $k \in [1, 10]$.

Método del codo

Se entrena K-Means para cada valor de k y se grafica la inercia J en función de k . La curva desciende de forma pronunciada entre $k = 1$ y $k = 4$, y a partir de ese punto el ritmo de descenso se reduce notablemente: de aproximadamente 1,300 puntos por paso antes de $k = 4$, a menos de 900 puntos después. Esto sugiere que $k = 4$ es el punto de equilibrio entre compactación interna y simplicidad del modelo.

Coefficiente de silueta

Para cada punto x_i se calcula:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

donde $a(i)$ es la distancia media intra-clúster (cohesión) y $b(i)$ es la distancia media al clúster vecino más cercano (separación). Valores cercanos a 1 indican clústeres bien separados y cohesivos.

Los resultados para cada valor de k fueron los siguientes:

k	Inercia	Coefficiente Silueta
2	11385.31	0.2300
3	9947.47	0.1983
4	8646.98	0.2108
5	7548.18	0.2325
6	6748.53	0.2271
7	6251.19	0.1882


8	5902.46	0.1827
9	5601.52	0.1918
10	5299.52	0.1850

El coeficiente de silueta alcanza su máximo en $k = 5$, seguido de $k = 2$ y $k = 4$. La curva de inercia muestra una caída pronunciada de $k = 1$ a $k = 2$, y descensos moderados hasta $k = 4$. A partir de $k = 4$ las reducciones se vuelven más pequeñas, aunque no se observa un punto de inflexión claro en ningún valor de k .

A pesar de que $k = 5$ tiene una silueta ligeramente superior a $k = 4$ de 0.2325 versus 0.2108, una diferencia de apenas 0.022, se seleccionó $k = 4$ ya que al examinar la composición del hipotético quinto clúster en $k = 5$ se observa que este grupo tiende a fragmentar el clúster 0: Agricultura de Temporal de Gran Escala, en dos subgrupos sin diferencias agronómicas sustanciales ya que ambos mantienen alta dependencia del temporal $> 85\%$ y baja siniestralidad $< 4\%$. La creación de un quinto clúster no revela un nuevo perfil estructural, solo divide un grupo existente.

Por el contrario, los cuatro perfiles obtenidos con $k = 4$ son estadísticamente distintos en las variables de agrupamiento y geográficamente coherentes con los hallazgos del EDA.

Así se selecciona $k = 4$ como número óptimo de clústeres.



Entrenamiento del Modelo y Visualización con PCA

Se entrenó K-Means con $k = 4$, semilla aleatoria fija en 42 para garantizar la reproducibilidad y $n_init=15$ inicializaciones para reducir la probabilidad de quedar


atrapado en un óptimo local desfavorable. La distribución de municipios resultantes fue:

Clúster	Municipios
Agricultura de Temporal de Gran Escala	939
Agricultura Tradicional de Temporal y Subsistencia a Pequeña Escala	954
Corredores Agrícolas Comerciales de Riego y Alta Productividad	486
Zonas de Siniestralidad Crónica y Vulnerabilidad Climática Crítica	79

Dado que el espacio de agrupamiento tiene 6 dimensiones, se aplicó Análisis de Componentes Principales (PCA) para proyectar los datos sobre las dos componentes de mayor varianza y permitir la visualización. La primera componente explica el 35.0% de la varianza y la segunda el 18.3%, con una varianza acumulada del 53.3%. La proyección evidencia separación clara entre los cuatro grupos, en particular el Clúster 3 aparece notablemente aislado en el extremo del eje PC1, lo que confirma que los municipios de vulnerabilidad crítica tienen un perfil estadísticamente muy distinto al resto.


Caracterización e Interpretación de los Perfiles

Los cuatro clústeres se caracterizan a partir de las estadísticas promedio de las variables originales, sin transformación logarítmica, para facilitar la interpretación agronómica:



Tenemos como resultado la cantidad de municipios asignados a cada clúster. El clúster 1, es el más numeroso con 954 municipios, seguido muy cerca por el clúster 0 con 939. El clúster 3 es el más pequeño con solo 79 municipios, lo que indica que el alto riesgo está concentrado en un número reducido de territorios.

Clúster	Municipios	Sembrada media (ha)	Siniestralidad	Prop. Temporal	Rendimiento (ton/ha)	Diversidad
0	939	200,353	3.36%	89.58%	86.2	18.0
1	954	24,632	92.47%	92.47%	13.9	6.4
2	486	194,652	33.58%	33.58%	2,371.4	26.8
3	79	106,697	87.97%	87.97%	14.9	15.1



Clúster 0: Agricultura de Temporal de Gran Escala (939 municipios)

Municipios con la mayor superficie sembrada absoluta del dataset, con un promedio de 200,353 hectáreas, y alta dependencia de la modalidad temporal (~90%). Presentan diversidad de cultivos de rango medio (~18 cultivos únicos) y rendimientos estables (~86 ton/ha). Su tasa de siniestralidad es baja (~3.4%), lo que sugiere que la escala productiva otorga cierta capacidad para absorber pérdidas localizadas. Geográficamente se concentran en Jalisco (101 municipios), Veracruz (97), Puebla (96), Oaxaca (76) y Estado de México (72), entidades que lideran la producción de granos de temporal a nivel nacional y que ya habían sido identificadas en el EDA como estados con gran superficie cosechada y relativamente baja siniestralidad proporcional. Este perfil representa los grandes corredores de agricultura de temporal del centro y occidente del país.

Clúster 1: Agricultura Tradicional de Temporal y Subsistencia a Pequeña Escala (954 municipios)

El grupo más numeroso del análisis. Municipios con superficie sembrada promedio baja (~24,631 ha), altísima dependencia del temporal (~92%), baja productividad (~13.9 ton/ha) y escasa diversidad de cultivos (~6 cultivos únicos). Su tasa de siniestralidad es moderada (~3.0%), aunque su vulnerabilidad estructural es mayor que la del Clúster 0 porque carecen de economías de escala para mitigar pérdidas. Este perfil está dominado por Oaxaca (474 municipios), seguido de Veracruz (101), Puebla (82), Chiapas (65) y Yucatán (49), lo que es plenamente coherente con el hallazgo del EDA que identificó a Oaxaca como el estado con mayor número de registros agrícolas del dataset, explicado por su alta diversidad municipal y su perfil de agricultura campesina de subsistencia. La coincidencia entre el estado modal del EDA y el estado dominante de este clúster valida la coherencia del agrupamiento.

Este perfil representa la agricultura campesina y de autoconsumo del sur-sureste del país, donde la milpa (el sistema tradicional de maíz, frijol y calabaza) es el eje productivo.

Clúster 2: Corredores Agrícolas Comerciales de Riego y Alta Productividad (486 municipios)

Municipios con infraestructura de riego que reduce drásticamente su exposición climática: sólo el 33.6% de su superficie es de temporal, frente al 88-92% de los otros clústeres de temporal. Presentan la mayor diversidad de cultivos (~27 cultivos distintos por municipio), los rendimientos más elevados del dataset (~2,371 ton/ha, casi 28 veces superior al Clúster 1) y la siniestralidad más baja (2.64%). Se concentran en Sonora (57), Michoacán (49), Puebla (40), Estado de México (33) y Guanajuato (31), correspondiendo a los principales distritos de riego del noroeste y el Bajío. Esta distribución geográfica es consistente con el hallazgo del EDA que identificó a Sinaloa como el estado donde la modalidad de riego supera ampliamente al temporal en superficie cosechada, y con la observación de que los estados del norte presentan los cultivos de mayor valor comercial. La infraestructura hídrica es el factor diferenciador más claro de bajo riesgo en el análisis.


Clúster 3: Zonas de Siniestralidad Crónica y Vulnerabilidad Climática Crítica (79 municipios)

Este clúster es el hallazgo más relevante del análisis no supervisado. Con apenas 79 municipios (el 3.2% del total), concentran una tasa de siniestralidad media del 30.90%, más de nueve veces superior a la del clúster más resiliente. Presentan alta dependencia del temporal (~88%), escala intermedia (~106,697 ha) y rendimientos muy bajos (~14.9 ton/ha). Los estados con mayor presencia son San Luis Potosí (33 municipios), Chihuahua (10), Tamaulipas (6), Zacatecas (6) y Durango (5), todos ubicados en el Altiplano Norte y la región semiárida del centro-norte del país, caracterizados por climas secos o semiáridos, baja precipitación anual y alta recurrencia de sequías.

Validación geográfica de los perfiles

Para verificar que los clústeres identificados son coherentes con la geografía de siniestros documentada en el EDA, se analizó qué entidades federativas concentran cada perfil.


Top 5 Estados por Clúster de Vulnerabilidad Agrícola



La validación más relevante ocurre en el Clúster 3 (Vulnerabilidad Crítica): San Luis Potosí (33 municipios), Chihuahua (10), Tamaulipas (6), Zacatecas (6) y Durango (5) corresponden exactamente a los estados con mayor área siniestrada acumulada identificados en el EDA. Este hallazgo tiene una validación directa: San Luis Potosí, Zacatecas y Tamaulipas fueron identificados como los tres estados con mayor área siniestrada acumulada en el periodo 2010–2024, con 1.75, 1.6 y 1.3 millones de hectáreas perdidas respectivamente. El hecho de que el clustering no supervisado haya agrupado a los municipios de estos mismos estados en el perfil de mayor vulnerabilidad constituye una validación cruzada robusta de que el modelo captura estructura real en los datos y no artefactos del preprocesamiento.

Estos 79 municipios representan los verdaderos hotspots de riesgo agrícola de México: zonas donde una mala temporada de lluvias puede significar la pérdida de casi un tercio de toda la superficie sembrada, comprometiendo directamente la seguridad alimentaria local y la viabilidad económica de miles de productores.

Comparación de siniestralidad entre perfiles




Comparamos la distribución de la siniestralidad entre los cuatro perfiles. El clúster 3 de Vulnerabilidad crítica no solo tiene el promedio más alto de 30.9% sino también la mayor dispersión, con municipios que alcanzan pérdidas del 100%. Los clústeres 0, 1 y 2 muestran distribuciones concentradas cerca de cero, con algunos outliers aislados que representan eventos climáticos extremos puntuales.

Este hallazgo tiene una validación directa con el EDA: San Luis Potosí, Zacatecas y Tamaulipas fueron identificados como los tres estados con mayor área siniestrada acumulada en el periodo 2010–2024, con 1.75, 1.6 y 1.3 millones de hectáreas perdidas respectivamente. El hecho de que el clustering no supervisado (que no utilizó la variable de estado como insumo—) haya agrupado a los municipios de estos mismos estados en el perfil de mayor vulnerabilidad constituye una validación cruzada robusta de que el modelo captura estructura real en los datos y no artefactos del preprocesamiento.

Estos 79 municipios representan los verdaderos hotspots de riesgo agrícola de México: zonas donde una mala temporada de lluvias puede significar la pérdida de casi un tercio de toda la superficie sembrada, comprometiendo directamente la seguridad alimentaria local y la viabilidad económica de miles de productores.

Perfil Comparativo de Variables por Clúster



Presentamos un gráfico de radar con los valores normalizados (0 a 1) de las seis variables de agrupamiento para cada clúster. Esta visualización permite comparar la “forma” de cada perfil de manera simultánea y detectar fortalezas y debilidades relativas.

- Clúster 0: Se combina la sembrada media (1.0) con alta Prop temporal (0.9509) y Diversidad media de (0.5695). Su proporción de riesgo de siniestro es muy bajo (0.0255) y el Rendimiento medio modesto (0.0307). Este perfil representa los grandes productores de temporal del centro-occidente del país (Jalisco, Veracruz, Puebla). Su vulnerabilidad estructural es baja a pesar de la alta dependencia climática, porque la escala productiva masiva (200,000 ha promedio) les otorga capacidad de absorción de pérdidas localizadas. La diversidad media (18 cultivos) también contribuye a su resiliencia.
- Clúster 1: Presenta como máximo Prop temporal (1.0) y el Precio medio (1.0) más alto, pero Riesgo siniestro, Sembrada media, Rendimiento medio, Diversidad media son los más bajos con (0.0). La gráfica se puede ver puntiaguda ya que es perfil corresponde a la agricultura de subsistencia y minifundio del sur-este de México (dominado por Oaxaca). A pesar de la baja productividad y escala, presentan precios relativamente altos porque sus

cultivos (maíz nativo, café, cacao) pueden alcanzar sobreprecio en mercados locales o de comercio justo. Su forma de radar “puntiaguda” indica estructuralmente frágiles ante cualquier cambio climático o de mercado.

- Clúster 2: Es el perfil más productivo y resiliente. Alcanza los valores máximos en Rendimiento medio (1.0) y Diversidad media (1.0), con sembrada media casi máxima (0.9676). Su Riesgo siniestro es nulo (0.0) y su Prop temporal también (0.0), lo que refleja que la infraestructura de riego elimina la dependencia climática, permitiendo rendimientos 28 veces superiores al clúster 1 y la mayor diversificación de cultivos (27 especies). Geográficamente se concentra en Sonora (principal productor de espárrago, con el 64.6% de la producción nacional, además del trigo y hortalizas), Michoacán (líder nacional en producción de aguacate, con el 75.2% de total nacional) y Guanajuato (fuerte productor de hortalizas, como el brócoli, zanahoria y lechuga).

Estos estados son pilares de la agricultura comercial de exportación donde cultivos de alto valor como el aguacate, espárrago y hortalizas dominan el paisaje agrícola. Dando como resultado la forma de radar más equilibrada.

- Clúster 3: Presenta el valor máximo en Riesgo siniestro (1.0), con Prop temporal muy alta (0.9236) y Sembrada media (0.4670). Sin embargo Rendimiento medio es prácticamente nulo (0.0004) y Precio medio es (0.0). Este perfil concentra la mayor vulnerabilidad estructural ya que se enfrenta a la alta exposición climática combinada con productividad casi inexistente.

Como el clúster se concentra en una zona semiárida como ya habíamos mencionado. En particular Tamaulipas ha enfrentado una crisis hídrica severa que ha dejado sin siembra más de 100,000 hectáreas y ha puesto en riesgo otras 100,00, principalmente de maíz, sorgo, hortalizas que son cultivos altamente dependientes del régimen de lluvias.

Complementariedad con el Modelo Supervisado

La segmentación obtenida enriquece los hallazgos del modelo supervisado de forma directa. El Clúster 3 confirma que los municipios de alta siniestralidad no son valores atípicos aislados sino una categoría estructural coherente, con un patrón común de escala intermedia, dependencia total del temporal y baja diversificación. Las predicciones del modelo supervisado pueden contextualizarse por perfil: un municipio del Clúster 3 que el modelo clasifica como alto riesgo requiere intervención urgente e

inversión en infraestructura hídrica; el mismo nivel de riesgo predicho en un municipio del Clúster 2 puede gestionarse con los mecanismos de seguro agrícola existentes. Ambos modelos comparten las variables `proporcion_siniestro` y `prop_temporal` como variables clave, pero desde perspectivas distintas: el supervisado las usa para predecir, el no supervisado para segmentar.

Persistencia y Reutilización del Modelo

El pipeline completo (el `StandardScaler` ajustado, la proyección PCA y el modelo K-Means entrenado) fue serializado en disco mediante pickle en el archivo `models/kmeans_pipeline.pkl`. Esto permite cargar el modelo en cualquier sesión futura y clasificar nuevos municipios sin necesidad de repetir el entrenamiento.

Para la demostración de reutilización se definió un municipio hipotético con características extremas: 8,000 hectáreas sembradas, 95% de área siniestrada, 98% de dependencia temporal, rendimiento de 0.5 ton/ha, precio medio de 4,200 pesos por tonelada y apenas 2 cultivos distintos. Tras aplicar las mismas transformaciones logarítmicas del pipeline de entrenamiento y escalar con el `StandardScaler` guardado, el modelo asignó este municipio al Clúster 3 (Zonas de Siniestralidad Crónica y Vulnerabilidad Climática Crítica), resultado coherente con su perfil de pérdida casi total, monocultivo y dependencia absoluta del temporal. La demostración confirma que el modelo persiste correctamente y produce predicciones consistentes de forma autónoma.

Patrón de Diseño: Pipeline

El código fuente del módulo de clustering, contenido en `src/clustering.py`, implementa el patrón de diseño Pipeline mediante la clase `AgroClusteringPipeline`. Este patrón es el más adecuado para este módulo porque el procesamiento de datos ocurre en etapas secuenciales bien definidas e interdependientes, donde la salida de cada etapa es la entrada de la siguiente:

```
DataLoader → preprocesar_y_agregar() → escalar_datos() → entrenar_kmeans → aplicar_pca()
```

El método `ejecutar()` formaliza este patrón encadenando todas las etapas automáticamente en una sola llamada, sin que el código cliente tenga que gestionar el orden ni la transferencia de datos entre pasos. Esto garantiza tres propiedades deseables: reproducibilidad, porque todas las transformaciones están encapsuladas y se serializan junto con el modelo; separación de responsabilidades, porque la

lógica de datos (DataLoader), el análisis exploratorio (EDAAnalyzer) y el modelado no supervisado (AgroClusteringPipeline) están en clases independientes; y extensibilidad, porque reemplazar K-Means por DBSCAN o GMM requiere modificar únicamente el método `entrenar_kmeans()` sin alterar el resto del pipeline.

MODELO SUPERVISADO 2: CLASIFICACIÓN DE NIVEL DE RIESGO CON XGBOOST

Objetivo del modelo

El tercer objetivo del proyecto consiste en predecir, antes de que concluya el ciclo agrícola, el nivel de riesgo de siniestro de una siembra. A diferencia del clustering —que caracteriza la vulnerabilidad estructural de los municipios— este modelo supervisado opera a nivel de registro (la combinación específica de año, estado, municipio, ciclo, modalidad y cultivo) y responde a la pregunta operativa: dada una siembra que apenas comienza, ¿qué tan probable es que sufra una pérdida y de qué magnitud?

Para ello se plantea un problema de clasificación multiclase sobre la variable `nivel_riesgo`, derivada en la etapa de preparación de datos a partir de `proporcion_siniestro`, con sus cinco categorías ordinales:

1. Sin siniestro: no se perdió superficie sembrada.
2. Riesgo bajo: pérdida marginal (hasta 10% del área).
3. Riesgo medio: pérdida moderada (10–40%).
4. Riesgo alto: pérdida severa (40–75%).
5. Pérdida crítica: pérdida casi total (más del 75%).

La clave del planteamiento es que el modelo solo puede usar información disponible ANTES de la cosecha; es decir, variables conocidas en el momento de sembrar.

¿Por qué XGBoost?

XGBoost (Extreme Gradient Boosting) construye árboles de decisión de forma secuencial, donde cada nuevo árbol corrige los errores del anterior mediante el algoritmo de gradient boosting. Se eligió este algoritmo por tres razones directamente alineadas con nuestro problema:

1. Es el estándar de referencia para datos tabulares heterogéneos como los nuestros, donde conviven variables numéricas y categóricas y las relaciones entre ellas son no lineales (recordemos que, en el EDA, Siniestrada mostró correlación lineal con ninguna otra variable).
2. Incorpora regularización integrada (parámetros gamma, lambda y alpha) que permite controlar el sobreajuste de manera explícita; este control constituye el eje central del análisis del modelo.
3. Maneja el desbalance de clases mediante ponderación de muestras (sample_weight), sin necesidad de alterar los datos originales con sobre o submuestreo.

PREPARACIÓN DE LOS DATOS PARA EL MODELO

Ingeniería de variables

A partir del dataset procesado se construyeron dos variables adicionales para enriquecer la información disponible:

- $\text{log_sembrada} = \log(1 + \text{Sembrada})$: el logaritmo comprime la fuerte asimetría de la superficie sembrada (muchas parcelas pequeñas y unas pocas enormes, detectada en el análisis de outliers), evitando que las grandes extensiones dominen el aprendizaje.
- $\text{interaccion_mod_ciclo} = \text{Idmodalidad} \times \text{Idciclo}$: captura el efecto combinado de regar o no según el ciclo productivo, ya que la vulnerabilidad de una siembra de temporal no es la misma en Primavera-Verano que en Otoño-Invierno.

Las variables categóricas de alta cardinalidad (estado, municipio y cultivo) se transformaron mediante Label Encoding. El conjunto final de predictores quedó conformado por 8 variables: Año, Estado, Municipio, Ciclo productivo, Modalidad (riego/temporal), Cultivo, $\log(\text{Superficie sembrada})$ y la interacción Modalidad $\times$ Ciclo.

Nota sobre la estandarización: XGBoost se basa en árboles de decisión y es invariante a la escala de las variables, por lo que NO se requiere normalizar ni estandarizar las numéricas. La única transformación de escala aplicada es $\log_{1p}$ sobre la superficie sembrada, para reducir su fuerte asimetría.

Prevención de fuga de información (data leakage)

Un punto metodológico crítico es que se EXCLUYEN deliberadamente las variables que solo se conocen después de la cosecha: Cosechada, Siniestrada, Volumenproduccion, Rendimiento, Precio, Valorproduccion y la propia proporcion_siniestro. Incluirlas constituiría una fuga de información, pues el modelo "haría trampa" usando el resultado para predecir el resultado. Al limitarnos a variables previas a la cosecha, el modelo simula fielmente su uso real: anticipar el riesgo antes de que ocurra.

Partición temporal (no aleatoria)


Para simular las condiciones reales de uso —entrenar con el pasado para predecir el futuro— los datos se dividieron por año, en lugar de aleatoriamente:

- Entrenamiento (2010–2020): 395,273 registros (73.0%) — ajuste del modelo.
- Validación (2021–2022): 66,293 registros (12.2%) — selección de hiperparámetros.
- Test (2023–2024): 80,260 registros (14.8%) — evaluación final e imparcial sobre datos nunca vistos.

El modelo final se entrena con train+validación (2010–2022, ~85% de los datos) y se evalúa sobre el test (~15%); la semilla aleatoria se fija (`random_state=42`) para garantizar reproducibilidad.

Tratamiento del desbalance de clases

Como se documentó en la preparación de datos, el problema presenta un desbalance extremo: la clase "Sin siniestro" concentra cerca del 95% de los registros (515,009 de 541,826), mientras que las cuatro clases de riesgo juntas apenas suman ~5%, siendo "Riesgo alto" la más rara (0.96%).




Distribución de la variable objetivo en escala lineal y logarítmica. El predominio de "Sin siniestro" hace que la exactitud (accuracy) por sí sola sea engañosa: un modelo que siempre predijera "Sin siniestro" acertaría el 95% sin aprender nada útil.

Este desbalance tiene dos consecuencias que guían todo el análisis. En primer lugar, obliga a usar métricas robustas al desbalance (F1-macro, balanced accuracy, Kappa, MCC, AUC-PR) en lugar de la accuracy. En segundo lugar, motiva el uso de `sample_weight`: a cada registro se le asigna un peso inversamente proporcional a la frecuencia de su clase. Los pesos calculados van desde 0.21 para la clase mayoritaria hasta 18.58 para "Riesgo alto", de modo que equivocarse en una clase rara penaliza mucho más que hacerlo en la mayoritaria, forzando al modelo a prestarles atención.

MODELO BASE (BASELINE)


Antes de optimizar nada, se entrenó un primer XGBoost con hiperparámetros por defecto, cuyo único propósito es servir de línea base de referencia: cualquier mejora posterior se medirá contra él. Se configuró con el objetivo `multi:softprob` (clasificación multiclase con probabilidades) y se registró la evolución del error en entrenamiento y validación para poder dibujar la curva de entrenamiento.



Curva de entrenamiento del baseline: log-loss multiclase y error de clasificación frente al número de árboles. Comparar el error en entrenamiento contra el de validación permite detectar sobreajuste: cuando el error de entrenamiento sigue bajando pero el de validación se estanca o sube, el modelo está memorizando ruido en lugar de aprender patrones generalizables.

El reporte de clasificación del baseline sobre validación arroja una accuracy de 0.866 pero un F1-macro de apenas 0.236. Esa enorme brecha es el síntoma directo del desbalance: el modelo acierta casi siempre en "Sin siniestro" (recall 0.88), pero fracasa en las clases de riesgo. Por ejemplo, en "Pérdida crítica" obtiene un recall

de 0.09 y una precisión de 0.01: detecta muy pocas y, de las que marca, casi todas son falsas alarmas. En conjunto, el modelo "crudo" sí intenta señalar riesgos, pero lo hace de forma muy deficiente. Este 0.236 de F1-macro es la vara que el resto del proceso buscará superar.



Matriz de confusión del baseline sobre el conjunto de validación. La diagonal contiene los aciertos; fuera de ella, los errores. Se observa que las confusiones tienden a darse entre niveles de riesgo adyacentes (medio↔alto, bajo↔medio), lo cual es esperable y menos grave en un problema ordinal.

Comparación con la línea base trivial (clasificador mayoritario)


Como verificación mínima exigida, el modelo debe superar a un clasificador trivial que siempre predice la clase mayoritaria ("Sin siniestro"). Ese clasificador logra una accuracy altísima (~0.96) por el puro desbalance, pero una balanced accuracy de solo 0.20 (1/5, azar entre cinco clases) y un F1-macro de ~0.20 (solo acierta una clase). El XGBoost lo supera ampliamente en las métricas que importan (F1-macro y balanced accuracy), confirmando que aprende señal real y no se limita a explotar la clase dominante.

REGULARIZACIÓN: gamma, lambda Y alpha

Esta es la sección central del análisis del modelo. La regularización combate el sobreajuste penalizando la complejidad del modelo. XGBoost ofrece tres "palancas" que se estudian primero una por una (para aislar su efecto) y luego en conjunto:

- gamma (γ): ganancia mínima exigida para abrir una división (split). Poda ramas poco útiles, produciendo árboles más simples.
- lambda (λ , regularización L2): penaliza la magnitud al cuadrado de los pesos de las hojas. Suaviza las predicciones y reduce la varianza.
- alpha (α , regularización L1): penaliza la magnitud absoluta de los pesos y puede llevarlos exactamente a cero, eliminando hojas poco informativas.

Experimento 1 — Efecto individual de gamma




Efecto de gamma sobre el F1-macro y el log-loss en validación.

El mejor valor es gamma = 0.1 (F1-macro 0.233), apenas por encima del valor por defecto. A partir de ahí, aumentar gamma degrada el desempeño de forma sostenida:

con gamma = 10 el F1-macro cae a 0.212 y el log-loss casi se duplica (de 0.48 a 0.72). La lectura es que, en estos datos, podar agresivamente los splits hace más daño que bien; basta una poda muy suave.


Experimento 2 — Efecto individual de lambda (L2)



Efecto de lambda (L2) sobre el F1-macro y el log-loss en validación.

Aparece la forma de "U invertida" esperada: el óptimo se da en $\lambda = 0.01$ (F1-macro 0.235, el mejor log-loss del barrido), y al superar $\lambda = 10$ el desempeño se deteriora. La mejora respecto al valor por defecto es pequeña, lo que anticipa una idea clave: ajustar un solo regularizador casi no mueve la aguja.

Experimento 3 — Efecto individual de alpha (L1)




Efecto de alpha (L1) sobre el F1-macro y el log-loss en validación.

El mejor valor es $\alpha = 0.01$ (F1-macro 0.235) y, de nuevo, la ganancia individual es marginal. Los tres experimentos confirman el mismo patrón: afinar gamma, lambda o alpha por separado deja el F1-macro estancado alrededor de 0.23–0.24. La pregunta natural es qué ocurre si se combinan.

Experimento 4 — Búsqueda conjunta con RandomizedSearchCV

Los efectos individuales ignoran las interacciones entre hiperparámetros. Por ello se exploraron 40 combinaciones aleatorias de los tres regularizadores junto con otros parámetros clave (`max_depth`, `learning_rate`, `n_estimators`, `min_child_weight`, `subsample`, `colsample_bytree`), validando cada candidata mediante validación cruzada estratificada de 3 particiones y optimizando el F1-macro.



Exploración del espacio de hiperparámetros: relación entre `max_depth`, `learning_rate` y `gamma` con el F1-macro obtenido en validación cruzada. Las nubes no son curvas suaves porque las demás dimensiones varían simultáneamente.

La búsqueda conjunta produce el salto más importante: el mejor candidato alcanza un F1-macro de 0.346 en validación cruzada, frente a ~0.23 de los ajustes individuales.

La configuración ganadora combina árboles más profundos y numerosos (`max_depth` = 9, `n_estimators` = 300) con regularización suave pero presente (`gamma` = 0.1, `reg_lambda` = 0.01, `reg_alpha` = 0.1), submuestreo de filas (`subsample` = 0.7) y de columnas (`colsample_bytree` = 0.8) y un `min_child_weight` = 10. La moraleja es que lo determinante no es cada palanca por separado, sino la interacción entre la capacidad del modelo y su regularización.

Tabla comparativa de las estrategias de regularización

Estrategia	F1-Macro
Baseline (valores por defecto)	0.2356
Mejor gamma ($\gamma = 0.1$)	0.2330
Mejor lambda ($\lambda = 0.01$)	0.2346
Mejor alpha ($\alpha = 0.01$)	0.2351
Búsqueda conjunta (RandomizedSearch)	0.3457

Los ajustes aislados no superan al baseline; el salto real (+0.11 de F1-macro, casi un +47% relativo) proviene de optimizar todos los hiperparámetros simultáneamente. Con esta configuración se construye el modelo final.

MODELO FINAL Y EVALUACIÓN


El modelo definitivo se entrenó con los mejores hiperparámetros de la búsqueda, combinando entrenamiento + validación (2010–2022) para aprovechar más datos, y se evaluó UNA SOLA VEZ sobre el test (2023–2024), que no participó ni en el entrenamiento ni en la selección de hiperparámetros. Esta es la estimación honesta del desempeño esperado en producción.

Se reporta un conjunto de amplias métricas porque ninguna métrica por sí sola describe bien un problema desbalanceado:


Métrica	Valor	Qué mide
Accuracy	0.9135	% de aciertos global (engañosa con desbalance)
Balanced Accuracy	0.3117	Recall promedio entre clases
F1-Macro	0.2776	F1 promedio sin ponderar (métrica guía)
F1-Weighted	0.9271	F1 ponderado por frecuencia
Precision-Macro	0.2696	Falsos positivos promediados por clase
Recall-Macro	0.3117	Falsos negativos promediados por clase
Log-Loss	0.2828	Calidad de las probabilidades
Cohen's Kappa	0.1613	Acuerdo corregido por azar
Kappa cuadrático	0.2848	Kappa que penaliza más los errores lejanos
MCC	0.1694	Correlación de Matthews (balanceada)
AUC-ROC (OvR, macro)	0.8521	Capacidad de ranking (1-vs-resto)
AUC-PR (macro)	0.2414	Área precision-recall (informativa con desbalance)

La interpretación conjunta de estos resultados es la siguiente. El modelo es un excelente detector de "todo en orden" (la clase "Sin siniestro" obtiene $F1 = 0.96$) y un buen ordenador del riesgo: el AUC-ROC macro de 0.852 indica que, aunque la decisión categórica falle, el modelo asigna probabilidades más altas a las siembras que efectivamente se siniestran. El F1-macro (0.278) y la balanced accuracy (0.312) son modestos, pero coherentes con la dificultad real del problema: detectar siniestros raros con un puñado de variables y sin información climática. Un dato


revelador es que el Kappa cuadrático (0.285) supere al Kappa lineal (0.161): como el cuadrático castiga más los errores "lejanos", que sea mayor confirma que, cuando el modelo se equivoca, suele hacerlo entre niveles vecinos, respetando el orden del riesgo.



Matriz de confusión del modelo final sobre el test, en versión absoluta (conteos) y normalizada por fila (que equivale al recall por clase). La diagonal de la versión normalizada muestra que "Sin siniestro" se recupera casi perfectamente, mientras que las clases de riesgo se reparten entre sí y hacia "Sin siniestro": el modelo subdetecta los siniestros, no los inventa.



Curvas ROC y Precision-Recall por clase (esquema One-vs-Rest). Las curvas ROC quedan claramente por encima de la diagonal de azar ($AUC \in [0,1]$; 0.5 es azar), evidenciando capacidad de ranking. Las curvas Precision-Recall, más exigentes bajo desbalance porque ignoran la enorme clase "Sin siniestro", quedan más bajas: al fijar un umbral de decisión, mantener buena precisión en las clases raras sigue siendo el cuello de botella.




F1-score por nivel de riesgo en el test. Revela qué clases domina el modelo (Sin siniestro) y cuáles le cuestan (las minoritarias), siendo las clases de riesgo intermedias las más difíciles de separar.

Comparación entre el baseline y el modelo optimizado

Para cuantificar la ganancia del proceso, se comparan ambos modelos sobre el mismo test imparcial:

Métrica	Baseline	Optimizado	Δ (mejora)
Accuracy	0.8664	0.9135	+0.0471
Balanced Accuracy	0.3356	0.3117	-0.0239
F1-Macro	0.2626	0.2776	+0.0150
F1-Weighted	0.9029	0.9271	+0.0242
Log Loss	0.4423	0.2828	-0.1594
Cohen Kappa	0.1372	0.1613	+0.0241
Kappa cuadrático	0.2429	0.2848	+0.0419
AUC-ROC (OvR macro)	0.8343	0.8521	+0.0178
AUC-PR (macro)	0.2369	0.2414	+0.0045

La optimización mejora casi todas las métricas: el log-loss se desploma de 0.442 a 0.283 (probabilidades mucho mejor calibradas) y suben accuracy, F1-weighted, Kappa cuadrático y los AUC. La excepción es la balanced accuracy / recall-macro (-0.024): el modelo optimizado es más conservador, lanza menos falsas alarmas a costa de atrapar un poco menos las clases minoritarias. Es un intercambio deliberado hacia un modelo más útil y confiable en conjunto.




Radar comparativo entre el baseline y el modelo optimizado sobre varias métricas. Cuanto mayor el área cubierta, mejor el modelo; permite ver de un vistazo las dimensiones en las que el modelo optimizado supera al baseline.

INTERPRETABILIDAD DEL MODELO

Un modelo preciso pero opaco es difícil de confiar. Para abrir la "caja negra" se emplean dos enfoques complementarios: la importancia nativa de XGBoost y los valores SHAP.


Importancia de variables (nativa de XGBoost)



Importancia de variables según las tres definiciones de XGBoost: weight (número de veces que se usa la variable para dividir un nodo), gain (ganancia promedio que aporta al usarse, la más informativa) y cover (número promedio de muestras afectadas). Permite identificar qué variables sostienen las decisiones del modelo.

Valores SHAP (SHapley Additive exPlanations)

SHAP descompone cada predicción en la contribución de cada variable, con base en la teoría de juegos. A diferencia de la importancia nativa, indica además en qué dirección empuja cada variable.



Importancia media absoluta de cada variable por clase de riesgo (SHAP).

Muestra qué variables pesan más para distinguir cada nivel de riesgo.






Diagrama beeswarm de SHAP para la clase "Pérdida crítica", la de mayor interés operativo. Cada punto es un registro: su posición horizontal es el impacto SHAP (a la derecha, empuja la predicción hacia "pérdida crítica") y el color representa el valor de la variable (rojo = alto, azul = bajo).




Dependence plots de SHAP para las tres variables más influyentes en la clase "Pérdida crítica". Muestran cómo cambia el impacto SHAP según el valor de cada variable, revelando relaciones no lineales.

ANÁLISIS DE ERRORES

Entender dónde y cómo falla el modelo es tan importante como su métrica global. La tasa de error global sobre el test es del 8.65% (6,939 de 80,260 registros). Más relevante que la cantidad es el tipo de error: las confusiones más costosas son "Pérdida crítica" clasificada como "Riesgo bajo" (78 casos) y como "Sin siniestro" (67 casos). Es decir, los errores que más preocuparían en operación —etiquetar una pérdida casi total como riesgo leve o nulo— existen y constituyen la principal limitación práctica del modelo actual.




Probabilidad predicha de "Pérdida crítica" frente a la proporción real de siniestro, coloreada por el nivel de riesgo real. Como nivel_riesgo se derivó de `proporcion_siniestro`, esta gráfica conecta la salida del clasificador con la variable continua original: idealmente, a mayor proporción real de siniestro, mayor probabilidad asignada a la clase crítica.



Tasa de error por estado (los 12 estados con mayor volumen de registros en el test). Permite identificar si existen regiones donde el modelo es menos confiable, información útil para focalizar mejoras o recolección de datos.


VALIDACIÓN CRUZADA Y ROBUSTEZ

La evaluación temporal proporciona una sola "foto" del desempeño. Para confirmar que el resultado es estable —y no fruto de una partición afortunada— se repitió la evaluación mediante validación cruzada estratificada de 5 particiones sobre los datos de desarrollo (entrenamiento + validación), sin incluir el test para no contaminar la evaluación final.



F1-macro por partición (fold) y comparación entre entrenamiento y validación en cada una.

El F1-macro a lo largo de los 5 folds es de 0.341 ± 0.0015 : una desviación estándar minúscula que indica que el resultado es muy estable. El AUC-ROC se mantiene alto (0.916). No obstante, el F1-macro de entrenamiento (0.518) supera notablemente al de validación (0.341), lo que evidencia un sobreajuste residual.



Curva de aprendizaje (F1-macro) en función del número de muestras de entrenamiento. Responde a la pregunta de si el modelo se beneficiaría de más datos o si ya alcanzó su techo.

La brecha final entre entrenamiento y validación es de 0.192, confirmando el sobreajuste que insinuaba la validación cruzada. Dado que las curvas no se han juntado, se sugiere que más datos —y sobre todo, mejores variables (información climática)— probablemente ayudarían más que seguir incrementando la regularización.

CIERRE DE LA PARTE 1 Y MOTIVACIÓN DE LAS SIGUIENTES

El modelo de la Parte 1 ya es sólido: el split temporal y los pesos por clase permiten evaluar honestamente sobre el futuro, la regularización conjunta elevó el F1-macro de 0.236 a 0.346 en validación cruzada, y la interpretabilidad (SHAP) da confianza sobre qué variables determinan el riesgo. Aun así, el análisis dejó ver limitaciones claras que motivan las dos partes siguientes:

- * Faltan variables CLIMÁTICAS, pese a que el proyecto trata del riesgo climático. Con solo variables de contexto, el modelo aprende el riesgo estructural promedio (qué zonas/cultivos suelen siniestrar) pero no distingue un año seco de uno lluvioso. → Se ataca en la PARTE 2.
- * El Label Encoding impone un orden artificial, el desbalance limita el recall de las clases raras, las probabilidades no estaban verificadas y el umbral de decisión no se ajustó. → Se atacan en la PARTE 3.

ENRIQUECIMIENTO CON VARIABLES CLIMÁTICAS

Motivación

El modelo anterior no usa ninguna variable de clima, a pesar de que el fenómeno que se quiere anticipar (el siniestro agrícola) es mayoritariamente climático. En esta parte se integran datos meteorológicos reales y se reentrena el modelo para medir, de forma controlada, cuánto mejora la predicción.

Fuentes de datos climáticos

Se usan dos fuentes complementarias, unidas al SIAP a nivel estado × año × ciclo:

- NASA POWER (comunidad de Agroclimatología): precipitación, temperatura media/máxima/mínima, humedad relativa y viento, mensuales 2010–2024, consultadas vía su API REST en el centroide de cada uno de los 32 estados.
- Índice de sequía tipo SPEI (escalas 3, 6 y 12 meses): en lugar de descargar el NetCDF global del CSIC (varios GB), se DERIVA con la misma metodología SPEI a partir de los datos de NASA POWER —balance hídrico (precipitación – evapotranspiración potencial por Thornthwaite), acumulado y estandarizado—. Valores negativos indican sequía.


Tras agregar el clima por ciclo agrícola y unirlo al SIAP, el dataset enriquecido conserva las 541,829 filas originales y añade 9 variables climáticas, con una cobertura del 98.1% de los registros (el ~2% sin clima corresponde a códigos de estado fuera del catálogo 1–32; XGBoost maneja esos faltantes de forma nativa). La unión es left join, por lo que las filas —y el test— son idénticas a la Parte 1, condición necesaria para una comparación justa.

Reentrenamiento controlado (ablación)


Para aislar el efecto del clima, se reentrena con los MISMOS hiperparámetros y el MISMO split que la Parte 1; lo único que cambia es el conjunto de variables. Así, cualquier diferencia en el test es atribuible al clima.

Métrica	Sin clima	Con clima	Δ (mejora)
Accuracy	0.9135	0.9441	+0.0306
Balanced Accuracy	0.3117	0.3236	+0.0119
F1-Macro	0.2776	0.3212	+0.0436
F1-Weighted	0.9271	0.9443	+0.0172
Log Loss	0.2828	0.2040	-0.0788
Cohen Kappa	0.1613	0.2425	+0.0812
Kappa cuadrático	0.2848	0.3849	+0.1001
MCC	0.1694	0.2426	+0.0731
AUC-ROC (OvR macro)	0.8521	0.8692	+0.0171
AUC-PR (macro)	0.2414	0.2723	+0.0309


El clima mejora TODAS las métricas del test, sin excepción. El mayor salto es el del Kappa cuadrático (+0.100), señal de que el clima ayuda a no confundir niveles lejanos de riesgo. Es importante que la balanced accuracy SUBA (0.312 $\rightarrow$ 0.324), revirtiendo la caída que el modelo optimizado mostraba en la Parte 1. A nivel de clase, el F1 de "Pérdida crítica" sube de 0.15 a 0.25, la mejora más relevante para el objetivo de seguridad alimentaria.




Comparación de métricas en el test (2023–2024) entre el modelo sin clima y con clima. El modelo con clima domina en todas las dimensiones.



Matriz de confusión normalizada del modelo con clima. Comparada con la del modelo sin clima (Figura 8), recupera mejor las clases de riesgo.



Importancia (gain) del modelo con clima. Las nueve variables climáticas entran entre las de mayor aporte —encabezadas por el viento, el índice de sequía SPEI-3 y la humedad—, por debajo del ciclo productivo, que sigue siendo dominante.



Importancia media SHAP por clase en el modelo con clima. Confirma que las variables climáticas contribuyen sobre todo a discriminar las clases de riesgo, no solo la mayoritaria.

Conclusión de la Parte 2: la señal climática aporta capacidad predictiva real sobre el riesgo de siniestro, más allá del riesgo estructural promedio que ya capturaban las variables de contexto. Esto confirma la hipótesis central del proyecto.

MEJORAS METODOLÓGICAS ADICIONALES

Sobre el modelo con clima (el mejor hasta ahora) se desarrollan cinco mejoras, todas evaluadas sobre el mismo test 2023–2024.

Criterio de optimización:

Un score compuesto alineado al negocio. A partir de esta parte, la búsqueda de hiperparámetros (RandomizedSearch y Optuna) y el ajuste del umbral dejan de optimizar el F1-macro y maximizan una métrica diseñada para este problema:

$$\text{Score} = 0.50 \cdot \text{F2(Pérdida crítica)} + 0.25 \cdot \text{Balanced Accuracy} \\ + 0.15 \cdot \text{Kappa cuadrático} + 0.10 \cdot \text{F1-macro}$$

La razón: el objetivo del problema es NO dejar pasar una pérdida crítica, pero sin disparar falsas alarmas. Optimizar solo el recall de la clase crítica es "hackeable" (el modelo predeciría crítico de más); por eso se usa F2 de esa clase, que prioriza el recall ~4× sobre la precisión pero sigue penalizando los falsos positivos. La balanced accuracy cubre el recall de las cinco clases, el Kappa cuadrático añade la penalización ordinal (confundir bajo↔crítico pesa más que alto↔crítico) y el F1-macro aporta el balance global. Los pesos concentran el recall donde de verdad importa (la clase crítica) sin duplicar señal con la balanced accuracy.

Target Encoding (codificación por tasa de siniestro)


Se sustituye el Label Encoding de estado/municipio/cultivo —que impone un orden artificial— por una codificación con la tasa histórica de siniestro de cada categoría, calculada SOLO con el train y con suavizado. Resulta la MEJOR variante: F1-macro 0.321 → 0.331, Kappa cuadrático 0.385 → 0.428, balanced accuracy 0.324 → 0.343 y AUC-PR 0.272 → 0.281, con AUC-ROC y log-loss prácticamente iguales.

Arquitectura en dos etapas

Se separa el problema en (1) un clasificador binario (¿habrá siniestro?) y (2) un clasificador de severidad sobre los registros siniestrados, combinando ambas probabilidades. Resultado MIXTO:

mejora la accuracy (0.944 → 0.953)
y el log-loss (0.204 → 0.185),
pero baja el F1-macro (0.331 → 0.303),
el Kappa cuadrático (0.428 → 0.351)
y la balanced accuracy (0.343 → 0.288).


Cabe subrayar que el clasificador de severidad NO heredó los hiperparámetros del modelo global, sino que recibió su PROPIA búsqueda bayesiana (Optuna, 50 trials, CV 3 folds) sobre los positivos del train, optimizando el F1-macro de las 4 clases de severidad —donde alcanzó 0.538 en CV con parámetros muy distintos ($\text{max_depth}=10$, $\text{min_child_weight}=2$)—. Aun así afinada, la arquitectura no mejora la detección de las clases minoritarias en este caso, por lo que la conclusión es ahora sólida: no compensa frente al modelo único con clima.



Búsqueda bayesiana dedicada al clasificador de severidad: (a) evolución del F1-macro de severidad por trial y (b) hiperparámetros más influyentes para este sub-problema, que difieren de los del modelo global.

Búsqueda bayesiana de hiperparámetros (Optuna)


Frente al RandomizedSearchCV, se prueba la optimización bayesiana (Optuna, TPE) en IGUALDAD DE CONDICIONES: misma métrica objetivo (score compuesto), mismo train completo y misma validación cruzada de 3 folds; la única diferencia es la estrategia de búsqueda (bayesiana, 50 trials, vs aleatoria, 40 candidatos). Resultado: Optuna alcanza un score compuesto en CV de 0.458, POR ENCIMA del 0.406 de la búsqueda aleatoria (+0.052, $\approx +13\%$ relativo). Es decir, cuando la comparación es justa, la búsqueda bayesiana SÍ supera a la aleatoria: aprovecha la información de los trials previos para encontrar mejores configuraciones. (El experimento anterior, con 25 trials sobre una submuestra, no podía demostrarlo.) El modelo de Optuna reajustado rinde en test un F1-macro de 0.299 —comparable, no un salto grande, por el cambio de distribución temporal 2023–2024—, pero el veredicto metodológico es claro: la búsqueda bayesiana es la estrategia de optimización más eficiente.



- (a) Evolución de la búsqueda bayesiana (score compuesto por trial y mejor acumulado) frente a la línea real del RandomizedSearchCV (0.406);
- (b) importancia de los hiperparámetros según Optuna.

Calibración de probabilidades


Se verifica y corrige la fiabilidad de las probabilidades (esencial si alimentan seguros agrícolas o asignación de apoyos). Entrenando en 2010–2020, calibrando (isotónica) en 2021–2022 y evaluando en 2023–2024, el Log-Loss baja de 0.225 a 0.194 y el Brier de 0.099 a 0.069.



Curva de calibración para la clase "Pérdida crítica": el modelo calibrado (azul) se acerca a la diagonal ideal frente al modelo sin calibrar (rojo).

Ajuste del umbral de decisión


Para detectar "Pérdida crítica", la regla argmax es demasiado conservadora. Barriando el umbral sobre $P(\text{Pérdida crítica})$ y eligiendo el punto que MAXIMIZA EL SCORE COMPUESTO (no solo el F1 binario de la clase), el recall de esa clase se multiplica por ~ 2.6 : pasa de 0.25 (argmax) a 0.65 en el punto óptimo (umbral ≈ 0.095), elevando el score compuesto de 0.296 a 0.396. Optimizar con el criterio de negocio —que pondera fuerte la recuperación de pérdidas críticas— empuja mucho más agresivamente a no dejar pasar siniestros casi totales que el antiguo criterio de máximo F1 (que llegaba a 0.44). Es la palanca más directa para la seguridad alimentaria, a costa de más falsas alarmas —un compromiso que se decide según el costo operativo.



Precisión y recall de la clase "Pérdida crítica" y el score compuesto en función del umbral de decisión. El óptimo del score compuesto se alcanza a un umbral bajo, que recupera muchas más pérdidas críticas.

Resumen de las mejoras

Variante	F1-Macro	Bal.Acc	Kappa cuad.	AUC-PR	Log-Loss
Con clima (base)	0.3212	0.3236	0.3849	0.2723	0.2040
Target Encoding	0.3311	0.3433	0.4283	0.2805	0.2044
Dos etapas	0.3032	0.2877	0.3511	0.2759	0.1851
Optuna (bayesiana)	0.2993	0.2814	0.3472	0.2737	0.2050




Comparación de las variantes de modelo completo sobre F1-macro, balanced accuracy y Kappa cuadrático. El Target Encoding es la mejor variante.

El Target Encoding es el mejor en las métricas de clases minoritarias; la arquitectura en dos etapas (ya con su clasificador de severidad afinado por separado) gana en accuracy y log-loss pero pierde en las métricas de minoritarias; y la búsqueda bayesiana, comparada en igualdad de condiciones, supera a la aleatoria en CV (score compuesto 0.458 vs 0.406), aunque en test queda a la par por el cambio de distribución temporal. La calibración y el ajuste de umbral aportan valor operativo sin cambiar el modelo. Nota: la columna de la tabla muestra las métricas de TEST; el veredicto de Optuna vs aleatoria se decide en validación cruzada (score compuesto), donde Optuna gana.

EVOLUCIÓN DEL MODELO: LAS TRES VERSIONES

Versión	F1-Macro	Bal.Acc	Kappa cuadr.
1 · Sin clima (Parte 1)	0.2776	0.3117	0.2848
2 · Con clima (Parte 2)	0.3212	0.3236	0.3849
3 · Clima + Target Encoding (Parte 3)	0.3311	0.3433	0.4283



Evolución del XGBoost en sus tres versiones sucesivas (test 2023–2024).

La mejora es MONÓTONA: el F1-macro sube 0.278 → 0.321 → 0.331 (+19% relativo en total), el Kappa cuadrático 0.285 → 0.385 → 0.428 y la balanced accuracy 0.312 → 0.324 → 0.343. Cada etapa aportó —el clima fue el salto más grande y el Target Encoding añadió una mejora adicional consistente— y ninguna empeoró el modelo: la versión final es claramente superior al punto de partida.

PERSISTENCIA Y REUTILIZACIÓN DEL MODELO

Como requisito técnico, el mejor modelo se serializa a disco con joblib (models/xgb_riesgo_clima.joblib, ~21 MB), guardando un bundle con el modelo, la lista de variables y los nombres de las clases para que sea autosuficiente. Se verificó la capacidad del modelo para ser recuperado desde disco y ejecutado para la inferencia sobre registros sin necesidad de un nuevo proceso de aprendizaje.

CONCLUSIONES

- El flujo completo —split temporal, manejo del desbalance con pesos, regularización sistemática e interpretabilidad— produce un modelo honesto y reproducible que supera ampliamente al clasificador trivial.
- La incorporación del CLIMA es la mejora de mayor impacto: confirma la hipótesis del proyecto y mejora todas las métricas del test (F1-macro 0.278 → 0.321, Kappa cuadrático 0.285 → 0.385), incluida la detección de "Pérdida crítica".
- Entre las mejoras metodológicas, el Target Encoding eleva aún más el desempeño (F1-macro 0.331), la calibración hace fiables las probabilidades (Brier 0.099 → 0.069) y el ajuste de umbral —optimizado con el score compuesto— multiplica por ~2.6 el recall de la clase crítica (0.25 → 0.65). La arquitectura en dos etapas, incluso con su clasificador de severidad afinado por separado, no superó al modelo con clima + Target Encoding; la búsqueda bayesiana, comparada en igualdad de condiciones (train completo, 50 trials), sí superó a la aleatoria en validación cruzada (score compuesto 0.458 vs 0.406), confirmándose como la estrategia de optimización más eficiente.

Limitaciones y trabajo futuro: el clima se integró a nivel estatal (no municipal) y el índice SPEI es una derivación, no el producto oficial del CSIC; afinar ambos es una mejora directa. Queda pendiente una función de costo asimétrica que penalice explícitamente subestimar pérdidas críticas, el clima a resolución municipal, y la integración en un sistema de alerta temprana operativo.

MODELO SUPERVISADO 1: CLASIFICACIÓN DE NIVEL DE RIESGO CON CATBOOST

Objetivo del modelo

El primer modelo supervisado busca responder una pregunta concreta: ¿es posible anticipar el nivel de riesgo de siniestro de una siembra mexicana antes de que ocurra la cosecha, usando únicamente la información disponible al momento de sembrar?

Para ello se plantea un problema de clasificación multiclase sobre la variable `nivel_riesgo`, derivada a partir de `proporcion_siniestro` con cinco categorías ordinales: Sin siniestro, Riesgo bajo, Riesgo medio, Riesgo alto y Pérdida crítica. La restricción central del modelo es que solo puede usar variables conocidas antes de la cosecha; cualquier dato que se genere después del evento queda excluido.

¿Por qué CatBoost?

CatBoost es un algoritmo de gradient boosting desarrollado por Yandex que construye un ensamble de árboles de decisión de forma iterativa: cada árbol nuevo corrige los errores que cometieron los anteriores. Se eligió por dos razones directamente alineadas con las características de este dataset.

La primera es su manejo nativo de variables categóricas. En lugar de requerir una codificación externa como Label Encoding o One-Hot Encoding, CatBoost calcula internamente una estadística del target para cada categoría usando únicamente los registros anteriores en el orden de entrenamiento. Esto es importante porque evita que información de registros futuros contamine la codificación de registros pasados, un problema conocido como data leakage que inflaría artificialmente las métricas.

La segunda es el Ordered Boosting. El boosting clásico tiene un sesgo sutil: cuando calcula el gradiente de un ejemplo, usa un modelo que ya fue entrenado con ese mismo ejemplo. CatBoost ordena los datos aleatoriamente en cada iteración y calcula el gradiente de cada registro usando solo los registros anteriores a él en ese orden, lo que produce estimaciones más confiables y reduce el sobreajuste, especialmente en datasets con fuerte desbalance de clases como este donde alrededor del 95% de los registros pertenecen a la clase "Sin siniestro".

Adicionalmente, se activó el ajuste automático de pesos por clase, que asigna mayor importancia a los errores cometidos en las clases minoritarias durante el entrenamiento, forzando al modelo a prestarles atención proporcional.

Preparación de los datos

Variables seleccionadas

La regla de exclusión fue clara: ninguna variable que se conozca después del siniestro puede entrar como predictor. Las columnas de producción: superficie cosechada, volumen producido, rendimiento, valor de producción; se excluyen porque solo están disponibles al cierre del ciclo. Las variables que sí entran son aquellas que el productor o el sistema de registro conoce al momento de sembrar: estado, ciclo productivo, modalidad hídrica, cultivo, superficie sembrada, precio de referencia y una señal histórica de siniestralidad.

Corrección del leakage en `proporcion_siniestro`

Esta variable merece atención especial. En el dataset original, `proporcion_siniestro` es el cociente entre superficie siniestrada y superficie sembrada del mismo registro, y `nivel_riesgo` es una discretización de ese mismo valor. Si se deja así, el modelo recibe la respuesta como entrada y obtiene métricas perfectas sin haber aprendido nada útil.


La corrección consiste en reemplazar ese valor por el promedio histórico de siniestralidad de la combinación estado-cultivo-ciclo-modalidad, calculado exclusivamente con los años anteriores al registro en cuestión. Para el primer año disponible de cada combinación se imputa cero por ausencia de historial. Esto convierte la variable en una señal genuinamente predictiva: lo que históricamente le ha ocurrido a esa combinación específica en temporadas pasadas.

Partición temporal

El split no es aleatorio sino cronológico, que es la única opción metodológicamente válida para datos de series de tiempo. Usar una división aleatoria permitiría que registros de 2023 aparecieran en entrenamiento y registros de 2011 en prueba, lo que daría al modelo acceso implícito a patrones futuros. El esquema adoptado es: entrenamiento con datos de 2010 a 2020 (395,273 registros), validación con 2021-2022 (66,296 registros) y prueba con 2023-2024 (80,260 registros).


Distribución de la variable objetivo y análisis exploratorio

Antes de entrenar es necesario entender la estructura de los datos con los que trabajará el modelo. La siguiente figura muestra la distribución de nivel_riesgo en escala lineal y logarítmica.




La escala lineal deja ver de inmediato el desbalance extremo: la clase "Sin siniestro" concentra alrededor del 95% de los registros, mientras que las cuatro clases de riesgo juntas apenas suman el 5% restante. La escala logarítmica es necesaria para poder apreciar que incluso las clases minoritarias cuentan con miles de registros, lo que es suficiente para que el modelo aprenda patrones si se compensan los pesos durante el entrenamiento.

Para complementar este panorama, la siguiente figura muestra los quince cultivos con mayor número de registros en el dataset.




El maíz grano domina por un margen amplio, lo que tiene implicaciones directas sobre el modelo: habrá visto muchas más combinaciones de maíz con distintos estados y ciclos que de cultivos especializados, generando mayor confianza en sus predicciones para ese cultivo y menor para los de baja frecuencia.

La siguiente figura muestra la distribución condicional del nivel de riesgo por estado, normalizada por fila, para los veinte estados con mayor número de registros.



Leer cada fila como una distribución de probabilidad sobre los cinco niveles de riesgo permite identificar perfiles geográficos claramente diferenciados. Los estados del norte con mayor infraestructura de riego concentran más masa en "Sin siniestro", mientras que los estados del sur y sureste con predominio de agricultura de temporal muestran distribuciones más dispersas hacia las clases de riesgo medio y alto. Esta variabilidad confirma que el estado no es una variable redundante: contiene información geográfica y climática real que el modelo puede aprovechar.



Las distribuciones están prácticamente separadas entre clases: la mediana crece de forma monótona desde "Sin siniestro" hasta "Pérdida crítica" y la separación entre los extremos abarca varios órdenes de magnitud. Esto anticipa que la siniestralidad histórica será la variable más informativa del modelo. La dispersión en las clases intermedias refleja que esas categorías capturan situaciones heterogéneas donde el mismo nivel de pérdida puede originarse por combinaciones muy distintas de estado, cultivo y ciclo, lo que las hace más difíciles de separar.

Línea Base


Antes de entrenar cualquier modelo con aprendizaje real se establece un clasificador trivial que siempre predice la clase más frecuente. En este dataset ese clasificador alcanza una exactitud (accuracy) de casi 98% sin haber aprendido absolutamente nada, simplemente porque la clase "Sin siniestro" domina el dataset. Sin embargo, su F1-macro es de apenas 0.20 porque nunca predice ninguna de las cuatro clases de riesgo. Esta es la trampa del accuracy en problemas

desbalanceados: una métrica aparentemente excelente que en realidad describe el peor clasificador posible desde la perspectiva del problema real.

CatBoost con parámetros por defecto ya supera esta línea base con un F1-macro de 0.2962, confirmando que las variables disponibles contienen señal real más allá de la distribución marginal del target.

Modelo	Accuracy	F1-Macro	Balanced Acc
Dummy (siempre Sin siniestro)	0.9781	0.1978	0.2000
CatBoost (defaults)	0.7190	0.2962	0.5196

Para entender cómo aprende el modelo a medida que se añaden árboles al ensamble, la siguiente figura muestra la curva de aprendizaje del modelo con parámetros por defecto.




La curva muestra la pérdida en entrenamiento y en validación a lo largo de las iteraciones. Las dos curvas descienden juntas y se estabilizan sin que la de validación empiece a subir, lo que indica que no hay sobreajuste con los parámetros por defecto. La línea verde marca la iteración 138, donde el mecanismo de early stopping detuvo el entrenamiento al detectar que la validación dejó de mejorar. Este comportamiento confirma que el modelo encontró un buen balance entre aprender los patrones del dataset y no memorizar ruido.

Optimización de hiperparámetros

Para mejorar el desempeño del modelo se realizó una búsqueda sistemática de hiperparámetros usando Optuna, una librería de optimización bayesiana. A diferencia de una búsqueda aleatoria, Optuna utiliza la información de los experimentos anteriores para proponer configuraciones cada vez más prometedoras, haciendo la búsqueda progresivamente más inteligente.


Se exploraron 30 combinaciones de parámetros sobre los más relevantes: número de árboles, profundidad máxima de cada árbol, tasa de aprendizaje y tres parámetros de regularización.

La siguiente figura muestra cómo evolucionó el F1-macro a lo largo de los 30 experimentos.



Los primeros experimentos son exploratorios y presentan alta variabilidad. A medida que Optuna acumula información, los intentos convergen hacia el mejor valor encontrado. La línea roja marca ese máximo: un F1-macro de 0.34 en validación, una ganancia del 14% relativo sobre los parámetros por defecto.

La siguiente figura muestra cuánto influyó cada hiperparámetro en ese resultado.



Los parámetros más determinantes resultaron ser la tasa de aprendizaje, que controla cuánto corrige cada árbol nuevo, y la profundidad, que determina qué tan complejas son las interacciones que el modelo puede capturar. Los parámetros de regularización tuvieron menor influencia individual, lo que sugiere que el modelo no sufre sobreajuste severo dentro del rango explorado.

Evaluación final en el conjunto de prueba


El modelo final se entrenó combinando los datos de entrenamiento y validación (2010-2022) para aprovechar el mayor historial posible, y se evaluó una única vez sobre los datos de prueba de 2023-2024. Esta evaluación única es un requisito metodológico: si se ajustan decisiones en función del resultado del test, ese conjunto deja de ser una estimación imparcial del desempeño real.

Los resultados principales fueron los siguientes: accuracy de 0.77, F1-macro de 0.31, balanced accuracy de 0.46 y AUC-ROC macro de 0.85. La diferencia entre el F1-macro (0.31) y el F1-weighted (0.85) es el síntoma más claro del desbalance: el modelo funciona muy bien en la clase mayoritaria pero enfrenta dificultades con las clases de riesgo intermedias, que tienen distribuciones de características que se superponen entre sí.

Un dato relevante es que el AUC-ROC macro de 0.85 es considerablemente más alto que el F1-macro. Esto indica que el modelo genera probabilidades con buena


capacidad de separación entre clases, pero la decisión final de asignar una etiqueta específica sigue siendo difícil por el desbalance y el solapamiento entre categorías vecinas. En términos prácticos, el modelo ordena bien el riesgo aunque no siempre acierta la categoría exacta.

El Kappa cuadrático de 0.26 aporta una perspectiva complementaria: como esta métrica penaliza más los errores entre categorías lejanas que entre categorías adyacentes, el hecho de que sea positivo confirma que cuando el modelo se equivoca, tiende a hacerlo entre niveles vecinos de riesgo y no entre extremos opuestos, lo cual es el comportamiento deseable en un problema ordinal.




La matriz normalizada equivale al recall por clase: la fracción de registros de cada nivel de riesgo que el modelo clasifica correctamente. "Sin siniestro" obtiene el recall más alto por ser la clase más frecuente y la más fácilmente separable. Las clases intermedias —Riesgo bajo y Riesgo medio— son donde el modelo comete más errores, porque sus distribuciones de características se superponen. El error más costoso desde la perspectiva operacional es predecir "Sin siniestro" cuando la realidad es "Pérdida crítica", y la matriz confirma que este error, aunque existe, es el menos frecuente de todos.

La siguiente figura muestra las curvas ROC para cada clase bajo el esquema uno-vs-resto.



Cada curva mide la capacidad del modelo para separar una clase del resto variando el umbral de decisión. Un AUC de 0.5 equivale al azar y 1.0 a separación perfecta. Las cinco clases quedan claramente por encima de la diagonal de referencia, lo que confirma que el modelo genera probabilidades informativas en todos los niveles de riesgo, no solo en la clase mayoritaria. La consistencia de este resultado con el AUC-ROC macro de 0.85 valida que la capacidad discriminativa del modelo es real. Por último, la siguiente figura muestra la tasa de error por estado para los veinte estados con mayor presencia en el conjunto de prueba.




Los estados con tasas de error superiores al 40% señalan zonas donde el modelo falla de forma sistemática. Esto puede deberse a tres causas: escasez de datos históricos de ese estado en entrenamiento, cambios en las condiciones agrícolas entre 2010-2022 y 2023-2024 que el modelo no pudo anticipar, o alta heterogeneidad interna del estado que hace difícil generalizar a partir de sus características agregadas. Identificar cuál hipótesis aplica a cada caso requeriría análisis adicional, pero la gráfica ya señala dónde enfocar mejoras futuras.

Interpretabilidad con SHAP

Para verificar que el modelo toma decisiones por razones coherentes con el dominio agrícola, se calcularon los valores SHAP, una técnica que descompone cada predicción en la contribución de cada variable. El análisis se enfocó en la clase "Pérdida crítica" por ser la de mayor relevancia operacional.


La siguiente figura muestra el beeswarm plot, donde cada punto representa un registro y su posición horizontal indica cuánto empuja esa variable hacia o en contra de la clase "Pérdida crítica".



proporcion_siniestro aparece en primer lugar con la mayor dispersión horizontal: los puntos rojos, que corresponden a alta siniestralidad histórica, se concentran a la derecha empujando hacia "Pérdida crítica", mientras que los puntos azules de siniestralidad baja se acumulan a la izquierda alejándose de esa clase. El estado y el cultivo siguen en importancia con contribuciones variables en ambas direcciones, lo que confirma que la geografía y el tipo de producción contienen información real


más allá del promedio histórico. La superficie sembrada y el precio tienen efectos menores pero presentes.

La siguiente figura resume esa misma información de forma más directa, mostrando la importancia media absoluta de cada variable.




El orden de las barras confirma la jerarquía de importancia: proporcion_siniestro domina claramente, seguida por el estado y el cultivo. La concentración de la importancia en pocas variables indica que el modelo no distribuye su decisión de forma uniforme sino que depende principalmente de un grupo reducido de predictores.

Para ilustrar cómo funciona este mecanismo en un caso concreto, la siguiente figura descompone la predicción de un registro individual correctamente clasificado como "Pérdida crítica".



El gráfico parte del valor base, que es la predicción promedio del modelo sin conocer nada del registro, y muestra cómo cada variable lo desplaza hacia arriba o hacia abajo hasta llegar a la predicción final. Las barras rojas aumentan la probabilidad de "Pérdida crítica" y las azules la reducen. En este caso la siniestralidad histórica es la contribución más grande, pero el estado y el cultivo amplifican esa señal, resultando en una predicción de alta confianza que no depende de una sola variable sino de su combinación.

Finalmente, la siguiente figura muestra cómo varía el efecto de `proporcion_siniestro` según la modalidad hídrica del registro.



Cada punto es un registro coloreado por su modalidad (Riego o Temporal). Si la relación entre siniestralidad histórica y su contribución SHAP fuera idéntica para ambas modalidades, los puntos de los dos colores se superpondrían. La separación vertical entre colores indica que la modalidad modifica el efecto de esa variable: en agricultura de temporal, donde la producción depende directamente de las lluvias, una alta siniestralidad histórica predice con mayor certeza pérdidas futuras. En agricultura de riego, la infraestructura hídrica puede compensar parcialmente ese historial, reduciendo el impacto de la misma señal sobre la predicción.

Persistencia del modelo

El modelo entrenado se serializó en disco mediante `joblib`, lo que permite cargarlo y usarlo para nuevas predicciones sin necesidad de reentrenarlo. Para demostrar su

funcionamiento, se evaluó sobre un registro de demostración correspondiente a una siembra de maíz grano en Oaxaca, modalidad Temporal, ciclo Primavera-Verano, con la proporción de siniestro imputada a cero como ocurriría en producción. El modelo asignó probabilidad de 93% a la clase "Sin siniestro", resultado coherente con el perfil histórico de esa combinación en el dataset.

Conclusiones del modelo

La hipótesis central se confirma parcialmente. Las variables disponibles antes de la cosecha contienen señal suficiente para distinguir los extremos del espectro de riesgo: "Sin siniestro" y "Pérdida crítica" se separan con mayor confianza, mientras que las clases intermedias presentan mayor confusión entre sí por el solapamiento de sus distribuciones de características.

La señal más fuerte proviene de la siniestralidad histórica, que en producción real se imputa a cero, lo que implica que el desempeño operativo sería menor al medido en prueba. Las principales limitaciones son la ausencia de variables climáticas, que son los determinantes físicos de los siniestros y el desbalance estructural 95/5 que limita cuánto puede aprender el modelo sobre los patrones de las clases raras. Ambas limitaciones señalan directamente las extensiones más prometedoras: incorporar datos de precipitación y temperatura por municipio y ciclo, y explorar estrategias adicionales de tratamiento del desbalance.

ARQUITECTURA Y DISEÑO

Patrón de diseño implementado

Pipeline

El patrón Pipeline estructura el procesamiento de datos como una secuencia de etapas ordenadas e independientes, donde la salida de cada paso es la entrada de la siguiente.

En el módulo de EDA, la clase EDAAalyzer encadena las etapas de carga, limpieza, derivación de variables, análisis exploratorio y exportación del dataset procesado. En el módulo de clustering la clase AgroClusteringPipeline formaliza este patrón de forma explícita mediante un método ejecutar() que encadena automáticamente la agregación municipal, la transformación logarítmica, el encalado, el entrenamiento de K-Means y la proyección PCA en una sola llamada, sin que el código tenga que gestionar el orden ni la transferencia de datos entre pasos. En el módulo de XGBoost, la clase XGBoostDataPrep aplica el mismo esquema encadenando la codificación, la partición temporal y el cálculo de pesos por clase.

Se usó Pipeline para estos módulos es porque necesitamos reproducibilidad, porque todas las transformaciones se encapsulan y se aplica en el mismo orden de entrenamiento y producción, también porque tenemos la separación de responsabilidades, ya que cada etapa vive en su propio método sin intervenir en las demás. Y por último la extensibilidad ya que cuando se agrega o reemplaza ya sea K-Means por DBSCAN en el clustering requiere modificar únicamente el método correspondiente sin alterar el resto del flujo

Strategy

El patrón Strategy define una familia de algoritmos que se intercambian y son encapsular en una interfaz común, permitiendo variar el comportamiento del sistema sin modificar el código que lo usa. Este patrón se aplica en el módulo de CatBoost a través de la clase CatBoostTrainer.

CatBoostTrainer encapsula toda la lógica del modelo (parámetros, entrenamiento, evaluación, serialización y carga) en un objeto que puede configurarse con distintas estrategias de hiperparámetros sin cambiar el código que lo invoca. Esto lo podemos observar en la fase 4 del notebook, donde Optuna instancia múltiples versiones de CatBoostTrainer con configuraciones distintas en cada trial, y en la

Fase 5, donde el modelo final se construye solo pasando los mejores parámetros al mismo constructor. Así el código cliente no necesita saber que configuración específica usa el trainer; solo llama a `entrenar()`, `evaluar()` y `predecir()`.

Se usó este patrón en CatBoost porque en la búsqueda de hiperparámetros requiere de instanciar y descartar decenas de variantes del mismo modelo.

Encapsular el comportamiento en CatBoostTrainer permite que Optuna trate cada configuración como una estrategia intercambiable, garantizando que la interfaz de entrenamiento y evaluación sea idéntica para el modelo con defaults, para cada trial de Optuna y para el modelo final, lo que elimina que haya inconsistencias entre versiones.

El código del análisis exploratorio de datos implementa el patrón de diseño Strategy debido a que permite definir una familia de algoritmos, encapsular cada uno de ellos en una unidad independiente, y permitir que sean intercambiables entre sí sin modificar el código que los utiliza.

La clase EDAAalyzer actúa como el contexto del patrón. Cada método público representa una estrategia concreta de análisis encapsulada de forma independiente. El patrón Strategy de EDAAalyzer se complementa con el patrón Repository implementado en la clase DataLoader. Mientras que Strategy define cómo se analiza el dato, Repository define cómo se accede a él, abstrayendo completamente la lógica de lectura del CSV detrás de una interfaz uniforme.

Layered Architecture


El Modelo 2 se construyó separando responsabilidades en tres capas, cada una con un patrón de diseño concreto, lo que desacopla el acceso a los datos, su preparación y el modelado:


- **Capa de acceso a datos:** patrón DAO (Data Access Object): la clase `DataLoader` (`src/data_loader.py`) encapsula la lectura del CSV, el manejo de la codificación (`latin-1/utf-8-sig`), la limpieza del BOM y una caché interna (`_df`). El resto del sistema obtiene los datos sin conocer su origen ni su formato.
- **Capa de preparación:** patrón Pipeline encapsulado: la clase `XGBoostDataPrep` (`src/xgboost_model.py`) expone una interfaz mínima de

tres métodos —`preprocess()`, `temporal_split()` y `get_sample_weights()`— que ocultan toda la complejidad interna: ingeniería de características (`log_semrada`, `interaccion_mod_ciclo`), codificación robusta a la codificación corrupta del CSV, partición temporal (`train ≤ 2020`, validación 2021–2022, `test ≥ 2023`) y cálculo de pesos balanceados.

- **Capa de modelado:** cliente/orquestador: el notebook `modelo_supervisado_2.ipynb` consume las dos capas anteriores y se concentra exclusivamente en entrenar el `XGBClassifier`, optimizar hiperparámetros (`Optuna` y `RandomizedSearchCV`) y ajustar el umbral de decisión.

Diagrama UML — Arquitectura por capas del Modelo 2 (XGBoost)





El diagrama de clases presenta la arquitectura completa del sistema, compuesta por siete unidades con responsabilidades claramente delimitadas y relacionadas entre sí mediante dependencias.

- **Repository DataLoader:** centraliza el acceso a los datos. Expone dos métodos públicos `cargar()` y `aplicar_tipos()` y abstrae detalles de lectura como la ruta, la codificación y el separador del CSV. El resto del sistema consume datos sin conocer su origen ni formato, lo que aísla cualquier cambio de fuente en una sola clase.
- **Strategy CatBoostTrainer:** encapsula el comportamiento del modelo de CatBoost como una estrategia intercambiable. Recibe un diccionario de parámetros y expone una interfaz uniforme de seis métodos: preparación, entrenamiento, evaluación, explicabilidad SHAP, predicción (etiqueta y probabilidades) y serialización/carga. Que `cargar()` sea un classmethod permite instanciar el trainer desde disco sin pasar por el constructor habitual, lo cual es necesario para el servicio de inferencia.
- **DataPrep XGBoostDataPrep:** prepara los datos exclusivamente para el modelo XGBoost. Contiene la lista de features, los codificadores y el mapa de niveles de riesgo, y expone tres métodos: `preprocess()` para ingeniería de variables y codificación, `temporal_split()` para la partición cronológica y `get_sample_weights()` para los pesos por clase. Al aislar esta lógica, el

notebook de modelado no necesita conocer ningún detalle de transformación.

- **Pipeline AgroClusteringPipeline:** formaliza el agrupamiento no supervisado como una secuencia de etapas. Sus atributos almacenan el scaler, la proyección PCA y el modelo KMeans ya ajustados. El método ejecutar() encadena automáticamente la agregación municipal, el escalado, la evaluación del número óptimo de clústeres, el entrenamiento y la proyección, de modo que el cliente solo llama a un único punto de entrada.
- **Component APIRest:** expone el sistema como servicio. Define tres endpoints: GET / para verificar disponibilidad, GET /health que reporta si el modelo está cargado, y POST /predict que recibe un RegistroAgricola y devuelve una RespuestaPrediccion. Depende de AgroClusteringPipeline para enrutar las predicciones y de los dos schemas para tipar entrada y salida.
- **Schema RegistroAgricola y SchemaRespuestaPrediccion:** son los contratos de la API. El primero define los campos mínimos que necesita cualquier solicitud de predicción (estado, cultivo, ciclo, modalidad, superficie y precio). El segundo estructura la respuesta devolviendo el nivel de riesgo predicho y un diccionario con las probabilidades por clase.

REUTILIZACIÓN DEL MODELO

Clustering, K-Means

El pipeline completo (StandardScaler, proyección PCA y modelo K-Means entrenado) fue serializado en disco mediante pickle en el archivo `models/kmeans_pipeline.pkl`. Esto permite cargar el modelo en cualquier sesión futura y clasificar nuevos municipios sin necesidad de repetir el entrenamiento ni disponer del dataset original.

La demostración de reutilización se realizó sobre un municipio hipotético con características extremas: 8,000 hectáreas sembradas, 95% de área siniestrada, 98% de dependencia temporal, rendimiento de 0.5 ton/ha, precio medio de 4,200 pesos por tonelada y apenas 2 cultivos distintos. Tras aplicar las mismas transformaciones logarítmicas del pipeline de entrenamiento y escalar con el StandardScaler guardado, el modelo asignó este municipio al Clúster 3 (Zonas de Siniestralidad Crónica y Vulnerabilidad Climática Crítica), resultado coherente con su perfil de pérdida casi total, monocultivo y dependencia absoluta del temporal. Esto confirma que el pipeline persiste correctamente y produce predicciones consistentes de forma autónoma.

Modelo Supervisado 1, CatBoost

El modelo entrenado fue serializado en disco mediante joblib en el archivo `models/catboost_model.pkl`. Para levantar el servicio de inferencia sin necesidad de reentrenamiento, el proyecto expone una API REST construida con FastAPI, que carga el artefacto al iniciar el servidor y lo mantiene en memoria para responder solicitudes de predicción en tiempo real.

Requisitos de entorno. Antes de levantar el servidor es necesario instalar las dependencias del proyecto:

```
pip install -r requirements.txt
```

En caso de error, pueden instalarse manualmente las dependencias críticas de la API:

```
FastAPI >= 0.100.0  
Uvicorn >= 0.36.0
```

Pydantic >= 2.0.0

Levantar el servidor. Desde el directorio raíz del proyecto:

```
bashuvicorn src.api:app --reload
```

o bien:

```
bashpython -m uvicorn src.api:app --reload
```

El modelo se carga automáticamente al iniciar, listo para recibir peticiones sin ningún proceso de entrenamiento adicional.

Endpoints disponibles.

Método	Ruta	Descripción
GET	/	Verificación de disponibilidad
GET	/health	Estado del servidor y confirmación de que el modelo está cargado
POST	/predict	Clasificación de nivel de riesgo para una siembra

Formato de entrada. El endpoint /predict recibe un objeto JSON con el esquema RegistroAgricola:

```
json{
  "Nomestado": "string",
  "Nomcultivo": "string",
  "Nomcicloproductivo": "string",
  "Nommodalidad": "string",
  "Sembrada": float,
  "Precio": float
}
```

La variable proporcion_siniestro se imputa automáticamente como 0.0 porque al momento de sembrar no se dispone de historial del ciclo actual.

Ejemplos de predicción. Las siguientes consultas pueden ejecutarse con curl, Postman o cualquier cliente HTTP:

Caso 1 Siembra de alto riesgo:

```
bashcurl -X POST http://localhost:8000/predict \
  -H "Content-Type: application/json" \
  -d '{
    "Nomestado": "ZACATECAS",
```

```

    "Nomcultivo": "Frijol",
    "Nomcicloproductivo": "P-V",
    "Nommodalidad": "Temporal",
    "Sembrada": 1.5,
    "Precio": 0.0
  }'
Respuesta:
json{
  "nivel_riesgo": "Pérdida crítica",
  "probabilidades": {
    "Sin siniestro": 0.055386,
    "Riesgo bajo": 0.000787,
    "Riesgo medio": 0.000307,
    "Riesgo alto": 0.004716,
    "Pérdida crítica": 0.938803
  }
}

```

El modelo clasifica la siembra como Pérdida crítica con una probabilidad del 93.9%, lo que es consistente con el perfil del Clúster 3 identificado en el análisis no supervisado: Zacatecas es uno de los estados con mayor área siniestrada acumulada del país, y el frijol de temporal en ciclo P-V concentra históricamente las mayores tasas de pérdida de la región.

Caso 2 Siembra de bajo riesgo:

```

bashcurl -X POST http://localhost:8000/predict \
-H "Content-Type: application/json" \
-d '{
  "Nomestado": "GUERRERO",
  "Nomcultivo": "Maíz grano",
  "Nomcicloproductivo": "P-V",
  "Nommodalidad": "Temporal",
  "Sembrada": 500.0,
  "Precio": 12000
}'

```

```

Respuesta:
json{
  "nivel_riesgo": "Sin siniestro",
  "probabilidades": {
    "Sin siniestro": 0.713954,
    "Riesgo bajo": 0.181491,
    "Riesgo medio": 0.057961,

```

```
"Riesgo alto": 0.009824,  
"Pérdida crítica": 0.036771  
}  
}
```

El modelo clasifica la siembra como Sin siniestro con una probabilidad del 71.4%, reflejando que la combinación de maíz grano en Guerrero bajo temporal P-V, a escala media y con precio de referencia alto, no presenta un historial de siniestralidad crítica.

En ambos casos la predicción corresponde a la clase con mayor probabilidad asignada por el modelo (regla argmax sobre la distribución de probabilidades de las cinco clases).

Modelo Supervisado 2, XGBoost

El mejor modelo (XGBoost con variables climáticas y Target Encoding) fue serializado en disco mediante joblib en el archivo `models/xgb_riesgo_clima.joblib`. El artefacto es un bundle autosuficiente que contiene el modelo entrenado, la lista de features requeridas y los nombres de las clases, de modo que puede cargarse y usarse en cualquier entorno sin acceso al código de entrenamiento.

La verificación de reutilización se realizó cargando el bundle desde disco y ejecutando predicciones sobre 8 registros del conjunto de prueba (2023–2024), obteniendo los mismos resultados que el modelo en memoria. Esto confirma que la serialización es consistente y que el artefacto puede integrarse en un servicio de inferencia o pipeline de producción independiente del proceso de entrenamiento.

```
import joblib  
  
# Cargar el modelo serializado  
cargado = joblib.load('models/xgb_riesgo_clima.joblib')  
modelo   = cargado['modelo']  
features = cargado['features']  
clases   = cargado['clases']  
  
# Predecir sobre nuevos registros  
predicciones = modelo.predict(X_nuevo[features])  
probabilidades = modelo.predict_proba(X_nuevo[features])
```

Conclusión

CONTEXTO Y OBJETIVOS DEL PROYECTO

Este proyecto integrador abordó, mediante técnicas de minería de datos, el problema de la vulnerabilidad agrícola y la seguridad alimentaria en México a partir de los datos abiertos de producción agrícola del SIAP a nivel municipal (2010–2024). El conjunto de datos original reúne las estadísticas de cada cosecha —superficie sembrada, cosechada y siniestrada, volumen, rendimiento, precio y valor de la producción— para cada combinación de año, ubicación, ciclo, modalidad hídrica y cultivo, y tras la fase de limpieza quedó consolidado en 541,829 registros.

El hilo conductor del trabajo es el siniestro agrícola: la pérdida total o parcial de un cultivo antes de la cosecha por causas climáticas (sequía, helada, granizo, inundación), biológicas o accidentales. Sobre esta base se persiguieron tres objetivos complementarios, cada uno materializado en un módulo del proyecto:

- Caracterizar el territorio agrícola y segmentar a los municipios según su perfil de vulnerabilidad (aprendizaje NO supervisado — `clustering.ipynb`).
- Anticipar el nivel de riesgo de siniestro de una siembra ANTES de la cosecha (aprendizaje supervisado — `modelo_supervisado.ipynb` con CatBoost).
- Profundizar en esa clasificación incorporando regularización sistemática, interpretabilidad y, sobre todo, la dimensión climática que da nombre al proyecto (`modelo_supervisado_2.ipynb` con XGBoost).

La hipótesis central que recorre todo el trabajo es que la información disponible al momento de sembrar —ubicación, cultivo, modalidad de riego, ciclo, escala y, finalmente, el clima— contiene señal suficiente para distinguir las siembras en riesgo antes de que ocurra el siniestro, de modo que la cobertura preventiva (seguros agrícolas, apoyos, infraestructura) pueda redirigirse de la lógica de remediar hacia la de prevenir.

CONCLUSIONES DEL ANÁLISIS NO SUPERVISADO (CLUSTERING)

Para entender la estructura del riesgo en el territorio, se agregó la granularidad original (cultivo–municipio–año) a una matriz de 2,458 municipios descritos por seis variables: escala productiva (superficie sembrada), riesgo histórico (proporción de siniestro), dependencia climática (proporción de temporal), productividad física (rendimiento), valor comercial (precio) y resiliencia ecológica (diversidad de cultivos). Tras la transformación logarítmica, el escalamiento estándar y la reducción con PCA, el algoritmo K-Means con K=4 (elegido por el método del codo, la silueta y la interpretabilidad) reveló cuatro perfiles agrícolas claramente diferenciados:

- Clúster 0 — Agricultura de Temporal de Gran Escala (939 municipios): grandes superficies (~200,000 ha), alta dependencia del temporal (~90 %), rendimientos estables y siniestralidad baja (~3.4 %). Predomina en Jalisco, Veracruz, Puebla, Oaxaca y el Estado de México.
- Clúster 1 — Agricultura Tradicional de Temporal y Subsistencia a Pequeña Escala (954 municipios): el grupo más numeroso; minifundio (~24,600 ha), dependencia casi total del temporal (~92 %), baja productividad (~14 ton/ha) y baja diversidad (~6 cultivos). Es la agricultura campesina del sur-sureste, fuertemente concentrada en Oaxaca.
- Clúster 2 — Corredores Agrícolas Comerciales de Riego y Alta Productividad (486 municipios): gran escala (~195,000 ha) con dominio del riego (67 %), rendimiento muy elevado y la siniestralidad MÁS BAJA del país (~2.6 %). Se ubica en los distritos de riego de Sonora, Michoacán, Guanajuato (Bajío), Puebla y el Estado de México.
- Clúster 3 — Zonas de Siniestralidad Crónica y Vulnerabilidad Climática Crítica (79 municipios): escala intermedia (~107,000 ha) pero una siniestralidad media del 30.9 %, más de nueve veces superior a la del grupo más resiliente, con casos que alcanzan la pérdida total. Se concentra en el

Altiplano Norte semiárido: San Luis Potosí (33), Chihuahua (10), Tamaulipas (6), Zacatecas (6) y Durango (5).

Tres conclusiones se desprenden de esta segmentación:

1. La variable con mayor poder de discriminación es la modalidad hídrica. La infraestructura de riego es el principal factor de resiliencia: el único clúster con dominio del riego (Clúster 2) presenta la menor siniestralidad, mientras que los grupos con más del 88 % de temporal cargan con todo el riesgo climático.
2. Escala y diversificación se asocian con resiliencia. Los municipios grandes y diversificados absorben mejor las pérdidas localizadas; el minifundio de baja diversidad (Clúster 1) es estructuralmente más frágil aun cuando su siniestralidad observada sea moderada.
3. El riesgo está geográficamente concentrado y no es aleatorio. El Clúster 3 coincide exactamente con los estados que el análisis exploratorio había identificado como los de mayor área siniestrada acumulada (San Luis Potosí, Zacatecas, Tamaulipas), lo que valida que el modelo capturó un patrón real de vulnerabilidad y no un artefacto del preprocesamiento. Estos 79 municipios constituyen el objetivo prioritario de política pública.

El pipeline completo (agregación, escalamiento, PCA y K-Means) se serializó y se demostró su reutilización: un municipio ficticio con 95 % de siniestro y 98 % de temporal fue asignado correctamente al Clúster 3, confirmando la consistencia agronómica y técnica del modelo.

CONCLUSIONES DEL PRIMER MODELO SUPERVISADO (CATBOOST)

El segundo módulo planteó la clasificación del nivel de riesgo de una siembra en cinco categorías ordinales —desde "Sin siniestro" hasta "Pérdida crítica"— usando CatBoost. Las decisiones metodológicas centrales fueron:

- Split TEMPORAL (entrenamiento 2010–2020, validación 2021–2022, prueba 2023–2024), única opción válida para datos de series de tiempo, que garantiza que el modelo nunca "vea" el futuro durante el aprendizaje.
- Corrección rigurosa de la fuga de información (data leakage): la variable `proporcion_siniestro` se recalculó como una media histórica con rezago temporal —la siniestralidad promedio de la combinación estado/cultivo/ciclo/modalidad en años anteriores— en lugar del valor del propio registro, que habría revelado la respuesta y producido métricas perfectas pero inútiles.
- Manejo del desbalance severo (~95 % "Sin siniestro") con `auto_class_weights='Balanced'` y métricas robustas (F1-macro, balanced accuracy) en lugar de la engañosa accuracy.

Tras optimizar hiperparámetros con Optuna (F1-macro de 0.296 con defaults a 0.338 en validación), el modelo final evaluado una sola vez sobre el test 2023–2024 obtuvo F1-macro 0.3070, F1-weighted 0.8485, ROC-AUC macro 0.8475 y Kappa cuadrático 0.2586. La lectura conjunta de estas métricas es la conclusión más matizada del módulo: el alto ROC-AUC frente al modesto F1-macro indica que el modelo ORDENA bien el riesgo (asigna mayor probabilidad a las siembras que efectivamente se siniestran), aunque la decisión categórica fina entre las clases intermedias de riesgo sigue siendo difícil por su solapamiento. El análisis SHAP confirmó que `proporcion_siniestro` concentra la mayor parte de la señal predictiva, y que los errores se producen predominantemente entre clases adyacentes —un comportamiento deseable en un problema ordinal—, siendo raro el error más costoso (predecir "Sin siniestro" cuando la realidad es "Pérdida crítica").

La limitación que este módulo dejó explícitamente señalada —y que motivó el tercer módulo— es la ausencia de variables climáticas, los verdaderos determinantes físicos del siniestro.

CONCLUSIONES DEL SEGUNDO MODELO SUPERVISADO (XGBOOST + CLIMA)

El tercer módulo reconstruyó el clasificador con XGBoost en tres secciones sucesivas, todas evaluadas sobre el mismo test imparcial 2023–2024.

Sección 1 — Modelo de contexto y estudio de regularización. A diferencia del módulo anterior, este modelo EXCLUYE `proporcion_siniestro` y toda variable post-cosecha, trabajando únicamente con ocho features de contexto (dónde, cuándo y qué se sembró). El estudio sistemático de la regularización mostró un hallazgo metodológico nítido: ajustar γ , λ o α por separado deja el F1-macro estancado en ~ 0.23 – 0.24 , mientras que la búsqueda CONJUNTA de todos los hiperparámetros lo eleva a 0.346 en validación cruzada (+47 % relativo). Lo que importa es la interacción entre capacidad del modelo y regularización, no cada palanca aislada. El modelo final alcanzó en test F1-macro 0.278 , accuracy 0.914 y AUC-ROC macro 0.852 , con un sobreajuste residual confirmado por la curva de aprendizaje (brecha train–validación de 0.192).

Sección 2 — Incorporación del clima (la hipótesis central del proyecto). Se integraron datos reales de NASA POWER (precipitación, temperatura media/máxima/mínima, humedad y viento) y un índice de sequía tipo SPEI derivado por balance hídrico, unidos al SIAP por estado×año×ciclo con una cobertura del 98.1 %. Manteniendo idénticos los hiperparámetros, el split y las filas —de modo que la ÚNICA diferencia fueran las variables climáticas— el clima mejoró TODAS las métricas del test sin excepción: F1-macro $0.278 \rightarrow 0.321$, Kappa cuadrático $0.285 \rightarrow 0.385$, balanced accuracy $0.312 \rightarrow 0.324$, log-loss $0.283 \rightarrow 0.204$ y, de manera especialmente relevante para la seguridad alimentaria, el F1 de la clase "Pérdida crítica" subió de 0.15 a 0.25 . Como la mejora es enteramente atribuible al clima, este resultado CONFIRMA la hipótesis central del proyecto: la señal climática aporta capacidad predictiva sobre el riesgo de siniestro más allá del riesgo estructural promedio. El índice de sequía y la precipitación emergieron como variables de peso real, respaldando la lógica agronómica.

Sección 3 — Mejoras metodológicas. Sobre el modelo con clima se evaluaron cinco mejoras con un score compuesto alineado al negocio (que pondera fuertemente la recuperación de la clase crítica):

- Target Encoding resultó la mejor variante de modelo (F1-macro 0.331, Kappa cuadrático 0.428, balanced accuracy 0.343), al codificar estado/municipio/cultivo por su tasa histórica de siniestro en lugar de enteros arbitrarios.
- La búsqueda bayesiana (Optuna), comparada en igualdad de condiciones, superó a la aleatoria en validación cruzada (score compuesto 0.458 vs 0.406), confirmándose como la estrategia de optimización más eficiente.
- La calibración isotónica mejoró la fiabilidad de las probabilidades (Brier 0.099 → 0.069), esencial si las salidas alimentan seguros o apoyos.
- El ajuste del umbral de decisión multiplicó por ~2.6 el recall de "Pérdida crítica" (de 0.25 a 0.65), la palanca más directa para la seguridad alimentaria, a costa de más falsas alarmas.
- La arquitectura en dos etapas, incluso con su clasificador de severidad afinado por separado, dio un resultado mixto: mejor accuracy pero peor en las métricas de clases minoritarias.

La evolución del modelo a lo largo del capítulo fue monótonamente creciente en las métricas clave (F1-macro 0.278 → 0.321 → 0.331; Kappa cuadrático 0.285 → 0.385 → 0.428), siendo el clima el salto más grande y el Target Encoding una mejora adicional consistente.

SÍNTESIS: LO QUE LOS TRES MÓDULOS DICEN EN CONJUNTO

Los módulos no supervisado y supervisado se complementan y se validan mutuamente. El clustering responde DÓNDE reside la vulnerabilidad estructural —una propiedad estática del territorio—, mientras que los modelos supervisados responden CUÁLES siembras concretas están en riesgo en un ciclo dado —una

predicción dinámica por registro—. Ambas miradas convergen en la misma conclusión de fondo:

- La dependencia del temporal (es decir, la exposición climática) es el eje que organiza tanto la segmentación de municipios como la importancia de variables del clasificador. El Clúster 3 de siniestralidad crónica y la mejora que aportan las variables climáticas al modelo XGBoost son dos manifestaciones del mismo fenómeno: el clima es el determinante dominante del siniestro.
- La consistencia geográfica es total. Los estados del Altiplano Norte que concentran el Clúster 3 (San Luis Potosí, Zacatecas, Chihuahua, Tamaulipas, Durango) coinciden con las regiones de mayor siniestralidad del EDA y con las zonas donde los modelos supervisados encuentran mayor dificultad, reforzando la solidez de todo el análisis.
- La señal predictiva es real pero parcial. Los modelos superan ampliamente a los clasificadores triviales —demuestran que las variables disponibles antes de la cosecha contienen información útil—, pero el severo desbalance 95/5 y el solapamiento entre niveles de riesgo intermedios mantienen el F1-macro lejos de valores de un sistema operativo de alta precisión. La hipótesis se confirma de forma robusta para los extremos del espectro ("Sin siniestro" y "Pérdida crítica") y de forma parcial para las clases intermedias.

¿Cuál modelo supervisado es el recomendado? El mejor modelo del proyecto es el XGBoost con clima + Target Encoding, que supera al CatBoost en las métricas que importan con clases desbalanceadas (F1-macro 0.331 vs 0.307, Kappa cuadrático 0.428 vs 0.259, balanced accuracy 0.343 vs 0.312). Más allá de los números, es preferible por dos razones de fondo: es honesto en producción —no depende de `proporcion_siniestro`, una variable post-evento que el CatBoost usa como su predictor más fuerte pero que debe imputarse a cero al momento de sembrar, lo que degradaría su desempeño real— y porque su ventaja proviene precisamente de la dimensión climática que da nombre al proyecto.

Conviene, no obstante, ACLARAR QUE LA COMPARACIÓN NO ESTÁ EN IGUALDAD DE CONDICIONES: los dos modelos usan conjuntos de variables distintos (el CatBoost incluye `proporcion_siniestro`; el XGBoost la excluye y añade clima), por lo que no es un duelo cabeza-a-cabeza perfecto sobre el mismo espacio

de features. La evidencia verdaderamente controlada —donde lo único que cambia son las variables— es la evolución interna del propio XGBoost: F1-macro 0.278 (contexto) → 0.321 (clima) → 0.331 (clima + Target Encoding). En ese experimento limpio cada paso mejora de forma monótona, lo que sostiene la recomendación. En suma: el XGBoost con clima + Target Encoding es el modelo de elección para un eventual despliegue, con la salvedad de que su superioridad frente al CatBoost se afirma sobre métricas y viabilidad operativa, no sobre una comparación de features idénticas.

LIMITACIONES

- Desbalance estructural: con ~95 % de registros sin siniestro, las clases más raras disponen de pocos ejemplos absolutos, lo que limita cuánto puede aprender el modelo sobre sus patrones específicos; los pesos por clase mitigan pero no eliminan el problema.
- Resolución del clima: las variables climáticas se integraron a nivel ESTATAL (no municipal) y el índice SPEI es una derivación propia, no el producto oficial del CSIC; ambos son proxies imperfectos de la realidad local.
- Compromiso de `proporcion_siniestro`: en el modelo CatBoost esta variable —la más predictiva— se imputa a cero en producción, por lo que el desempeño real sería menor que el medido en test; el modelo XGBoost evita este problema al excluirla, a cambio de prescindir de su señal.
- Cambio de distribución temporal: la brecha entre validación cruzada y test (p. ej. 0.346 → 0.278 en XGBoost) es coherente con un repunte de siniestros en 2023–2024, lo que recuerda que el riesgo agrícola es no estacionario.

TRABAJO FUTURO Y RECOMENDACIONES

- Enriquecer el clima a resolución MUNICIPAL y por ciclo, e idealmente incorporar el producto SPEI oficial; es la extensión de mayor impacto esperado, dado que el clima fue el mayor salto de desempeño observado.
- Atacar el desbalance con estrategias adicionales (función de costo asimétrica que penalice explícitamente subestimar una "Pérdida crítica", matriz de costos operativos) y considerar modelos especializados por macro región geográfica.
- Focalizar la política pública en los 79 municipios del Clúster 3: es donde los seguros agrícolas, la infraestructura hídrica y el apoyo directo tendrían el mayor impacto marginal sobre la seguridad alimentaria nacional.

CIERRE

El proyecto recorrió el flujo completo de un trabajo de minería de datos —comprensión y limpieza del dato, segmentación no supervisada del territorio, y clasificación supervisada del riesgo con dos algoritmos de gradient boosting, estudio de regularización, interpretabilidad con SHAP, incorporación de la dimensión climática y un abanico de mejoras metodológicas— aplicado a un problema de alto valor social: la relación entre el riesgo climático y la seguridad alimentaria en México. La conclusión esencial es que la vulnerabilidad agrícola mexicana es estructural, está geográficamente concentrada y está gobernada por la exposición climática; que esta exposición es predecible en grado útil pero imperfecto con la información disponible antes de la cosecha; y que la incorporación explícita de variables de clima es el camino más prometedor para convertir el análisis en una herramienta preventiva. El valor del trabajo no reside únicamente en las métricas alcanzadas, sino en haber identificado con evidencia dónde, por qué y bajo qué condiciones la agricultura mexicana pierde sus cosechas —el primer paso para protegerla.

REFERENCIAS

Datos Abiertos Agrícola DGSIAP. (s. f.).

<https://nube.agricultura.gob.mx/datosAbiertos/Agricola.php>

Nicolás, I. M. M. (2025, diciembre 2). *Los 10 retos de la agricultura mexicana*. ICL MX.

<https://icl-growingsolutions.com/es-mx/agriculture/knowledge-hub/mexican-agriculture-top-10-challenges/#title10>

NASA POWER: NASA Langley Research Center (LaRC). (s. f.). *POWER Data Access Viewer*. <https://power.larc.nasa.gov/data-access-viewer/>

SPEIbase: Beguería, S., Vicente-Serrano, S. M., Reig-Gracia, F., & Latorre-Garcés, B. (2023). *SPEIbase* v.2.9 [Dataset]. DIGITAL.CSIC.

<https://doi.org/10.20350/digitalCSIC/15470>

Secretaría de Agricultura y Desarrollo Rural. (s. f.). *Hablemos de la agricultura en México* (Parte 1).

<https://www.gob.mx/agricultura/articulos/hablemos-de-la-agricultura-en-mexico-parte-1>

Secretaría de Agricultura Y Desarrollo Rural, S. (s.f.). *Oaxaca, sólido productor agrícola y gastronómico*.

<https://www.gob.mx/agricultura/articulos/oaxaca-solido-productor-agricola-y-gastronomico>

Secretaría de Agricultura Y Desarrollo Rural, S. (s.f.). *Maíz, cultivo de México*.

<https://www.gob.mx/agricultura/articulos/maiz-cultivo-de-mexico>

Infofuturo. (2024, 25 junio). *¿Qué es el clustering de datos?: funcionamiento, tipos y aplicaciones*. ISDI España.

<https://www.isdi.education/es/blog/clustering-de-datos-funcionamiento>

Mijangos, V. S. (s.f.). *06 KMeans*. En *Inteligencia Artificial*. GitHub Pages.

<https://victormijangosdelacruz.github.io/InteligenciaArtificial/05%20Aprendizaje/06%20kMeans.html>

Axayacatl, O. (2022, 26 enero). *Cultivos que tendrán mayor crecimiento en los siguientes años*. NETAFIM. An Orbia Bussines.

<https://www.netafim.com.mx/blog/Cultivos-que-tendran-mayor-crecimiento-en-los-siguientes-anos/>

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2017). *CatBoost: Unbiased boosting with categorical features*. arXiv. <https://arxiv.org/abs/1706.09516>

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (2nd ed.). O'Reilly Media.
http://14.139.161.31/OddSem-0822-1122/Hands-On_Machine_Learning_with_Scikit-Learn-Keras-and-TensorFlow-2nd-Edition-Aurelien-Geron.pdf